

走进gplearn——再谈遗传规划在因子挖掘中的运用

原创 Mr.Bright 跟puppy玩量化 2022-12-22 20:15 发表于四川

近期随着全国疫情政策的全面放开，全民免疫正在成为现实。面对这种放开，有支持的同时一定有人反对，事物的两面性体现在疫情和病毒演化中，当样本（整个人群）足够大，大数定理一定会被服从。


最终新冠和人类能否和谐共处我们不得而知，对于人体系统来说，免疫能力需要和病毒的进化之间达成一种均衡。我不是生物学/病毒学方面的专业人士，经过查资料得知人的免疫系统和病毒的进化之间存在一种均衡——以人的免疫系统为环境，病毒的各项能力作为指标，相互之间出现“角力”行为。

作为一个quant，我很自然地想起经常在使用的gplearn模块，该模块基于crossover、mutation and reproduction，用于基础因子之上，经过不同的算法组合，在大量运算和进化、变异及繁殖的过程中挖掘更强大的因子。

前期我曾在《更高效的因子挖掘方式——遗传规划及其实战应用》一文中介绍了gplearn模块及其基本原理和基础使用模式。

一、重要参数及其选择

```
604 est_gp = SymbolicTransformer(  
605     feature_names=fields,  
606     function_set=function_set,  
607     init_depth=(2,3), # init_depth属于initial函数，用于控制生成深度，默认参数为2-6  
608     generations=generations,  
609     # hall_of_fame=100,  
610     n_components=100, # 最终输出多少个因子  
611     metric=metric, #'spearman'秩相关系数 metric  
612     population_size=population_size,  
613     tournament_size=80,  
614     random_state=random_state,  
615     verbose=2,  
616     parsimony_coefficient=0.2,  
617     p_crossover = 0.4, # 这个不能设置的太高，0.9实在是太高了  
618     p_subtree_mutation = 0.01,  
619     p_hoist_mutation = 0.12,  
620     p_point_mutation = 0.01,  
621     p_point_replace = 0.2,  
622     n_jobs = n_jobs )
```



gplearn.genetic 中 下 设 SymbolicTransformer，SymbolicRegressor 和 SymbolicClassifier三个模块，分别用于公式生成、模式回归和模式分类，其中regressor已经被证明优于lasso、ridge和xgboost。

在SymbolicTransformer模块中，如下参数极度重要，需要被严格关照：

1、init_depth为公式深度，其默认参数为（2,6），也就是默认情况下公式组合最浅为2层，最深为6层。我测试该参数的结果如下所示：

```
[Parallel(n_jobs=24)]: Done 24 out of 24 | elapsed: 1.5min finished
0    15.15    0.918135    6    1    N/A    7.42m
      fitness      expression depth length
fct_gp_20  -13.4  add(min(inv(sqrt(max(mul(volume, -0.714), inv(... 6    72
fct_gp_17  -12.8  add(sub(min(add(mul(inv(high), add(volume, low... 6    69
fct_gp_5   -12.2  add(mul(min(add(add(inv(high), sub(low, high)))... 6    66
fct_gp_8   -11.6  sub(sub(sin(sqrt(min(sqrt(open), min(open, low... 6    63
fct_gp_10  -11.4  min(sub(add(div(sub(min(volume, low), min(clos... 6    62
fct_gp_19  -9.2   max(add(add(div(max(max(volume, high), inv(vol... 6    51
fct_gp_7   -8.2   sub(min(inv(div(log(add(0.893, 0.951)), div(sq... 6    46
fct_gp_18  -7.4   add(mul(div(sqrt(add(high, low)), sub(sub(clos... 5    42
fct_gp_14  -7.0   add(max(sub(sqrt(div(close, open))), div(high, ... 6    40
fct_gp_12  -4.6   sin(mul(mul(max(close, sin(add(open, close))),... 6    28
fct_gp_4   -4.6   add(min(low, min(sub(volume, log(low)), open))... 6    28
fct_gp_11  -2.4   mul(0.955, sub(sub(close, sin(inv(volume))), d... 5    17
fct_gp_9   -2.2   mul(mul(min(sub(sub(-0.473, close), mul(low, l... 5    16
fct_gp_16  -2.0   sqrt(sqrt(sin(sub(add(add(open, close), add(cl... 6    15
fct_gp_13  -1.8   div(add(max(low, volume), add(close, close)), ... 3    14
fct_gp_1   -1.8   sin(sub(sin(mul(min(add(volume, close), max(cl... 6    14
fct_gp_6   -1.6   sin(sub(low, div(div(sin(low), sin(low))), sin(... 5    13
fct_gp_3   -1.6   sqrt(max(mul(max(volume, high), max(high, clos... 4    13
fct_gp_2   -1.0   sin(sin(sin(mul(mul(high, close), add(low, vol... 5    10
fct_gp_15  -0.2   sub(add(open, close), inv(open))
time cost:----- 89.6425449848175    s-----
(base) PS E:\Data pool\demo\factor_model> 
```

可以很清晰地看到，当depth超过4时，组合算法过于复杂，可解释性令人质疑。对于笔者来说，认为该参数的最佳范围为（2,4）。

2、population，初始random生成公式的时候生成多少个，这个指标根据各自能够承受的时间和电脑的实际算力进行，一般上我会将这个指标设置为20万，36万或者50万，同时需要注意的是n_jobs参数，如果选择的population比较大，建议把n_jobs设置为-1，把电脑的核全部用上。

3、tournament_size, 它的大小与进化论中的选择压力息息相关：tournament_size越小，选择压力越大，算法收敛的速度可能更快，但也有可能错过一些隐藏的优秀公式，这个公式是最难选择的，为每一个generation中，被选择至下一轮的因子数目。

4、n_components，输出因子的数量，在这个过程中最终输出多少个因子，我采用的参数是如果population为10万个，最终输出100个因子，在进行分门别类测试。

二、参数之外的核心基础要素

1、feature_names，也就是所选择的fields，一般上大家选择的fields是一些基础因子，比如最常见的是一些使用者把open, high, low, close, volume以及amount几个最为基础的指标输入进去，让gplearn以上述六个基础数据进行深度挖掘。这种模式并非不可以，但是很可能需要浪费大量的时间用于因子挖掘。在这个问题上，我建议还是先对上述数据进行初步处理，再做深度进化，是比较好的选择；

2、function_set，该模块一般上分为init_function和user_function，其中init_function主要是add, sub, mul, div, sqrt, log, inv, sin, cos, tan, max和min几个基础计算公式，但是user_function是体现使用者算法功底的部分，也是见仁见智的部分，建议每位quant在这个部分深度发力；

3、metric，该模块为损失函数，也是非常核心的模块，默认函数为spearman或者pearson系数，如果挖掘出来的因子将使用于decision tree model，比较建议使用spearman作为metric损失函数。同时metric模块完全可以按照自己的需求设置损失函数，比如说gross return, sharpe ratio, sortino ratio等，将上述函数def好之后，在metric部分使用make_function函数进行设置即可。

三、遗传规划中最容易出错的部位

1、field方面，绝不能仅仅是open, high, low, close, volume这样简单的基础数据，亲证这样输入的结果是garbage in，那么结果大概率是garbage out；

2、输入的field需进行滚动标准化，以去除其量纲对数据的影响，同时必须以事件驱动模式作为回测基础，否则会包含大量的未来信息，导致回测和实战之间产生缺口；

3、gplearn为机器学习模型，那么该模型对于样本的要求是比较高的，10k以下样本的数据需要谨慎使用，否则会造成严重的过拟合；

4、在对dataset使用gplearn进行处理之前，仍然需要对齐进行严格的train-test划分，否则在测试数据的过程中会出现严重错误；

5、train部分数据预处理过程中，需要使用nan_to_num函数分别对x_train和y_train部分进行处理，否则在div或者idv算法中可能出现大量的np.inf或者-np.inf从而产生错误。

最后，道阻且长，无论是因子挖掘这条路，还是疫情的修复，都祝各位顺利，远离伤病，积极上分。

喜欢此内容的人还喜欢

怎么找到趋势性最强的品种？用ER指标分辨震荡/趋势市场！
跟puppy玩量化



一文读懂「做市商」的底层逻辑
跟puppy玩量化



自定义技术指标，动量轮动策略-创业板年化20%+（附源码）
七年实现财富自由

