

华泰金工 | “GPT如海”：RAG与代码复现

原创 林晓明何康沈洋 华泰证券金融工程 2024年05月08日 15:28



本文探索大语言模型在量化研究领域中进行代码复现的实际应用。传统的大语言模型仅能处理单一模态的数据，多模态大模型则拥有多模态感知和生成能力，以多模态大语言模型为基础的代码复现系统可能更具准确性与实用性。以代码复现需求为切入点，我们基于多模态大模型和RAG技术构建了一个完善易用的代码复现框架，我们称之为“GPT如海”。在框架内部，“GPT如海”既依赖于多模态大模型对于不同模态信息的提取能力，也离不开RAG技术对海量文档的检索支持，最终使得基本的GPT-4模型在应用框架的加持下发挥出了极为出色的代码复现效果。同时，我们针对不同应用场景设计了两套代码复现模板，分别是因子代码复现和人工智能量化策略代码复现。本文也对比了多模型代码复现效果，结果显示，小模型也可“纳须弥于芥子”，通义千问和Llama3以小参数体量博得不错的代码生成效果，体现出小型模型“纳须弥于芥子”的潜力。

核心观点

人工智能系列之77：基于GPT和RAG技术的代码复现系统

本文探索大语言模型在量化研究领域中进行代码复现的实际应用。基于GPT-4系列模型和RAG技术，本文构建了一个完善且易用的代码复现框架，我们称之为“GPT如海”。在框架内部，GPT多模态模型提供了提取图片语义信息的能力，RAG模块则有效支持海量文档的切分与检索，为大模型提供外部知识库，基于此，“GPT如海”能够根据输入的图片或PDF文档，准确提取与代码复现任务相关的信息，并进行代码自动化生成。测试结果显示，“GPT如海”能较准确地复现因子计算和人工智能量化策略代码。

多模态大语言模型：勾勒图片中蕴含的语义信息

传统的大语言模型仅能处理单一模态的数据，例如文本，而多模态大模型拥有多模态感知和生成能力，例如图像、语音和视频，在交互性上更贴近通用人工智能的愿景。近年来，多模态大模型已经得到了长足的发展，目前多模态大模型已经具备同时感知文本、图像、音频的能力，并且逐渐发展出生成多模态内容的能力。在量化研究领域，研究报告同样蕴含较为丰富的多模态数据，包括文本和图像数据，在多模态大语言模型图像感知能力的加持下，代码复现系统可能会更具准确性与实用性。

检索增强生成：为大语言模型披上知识之铠

RAG (Retrieval-Augmented Generation, 检索增强生成) 是一种通过使用外部来源事实构建向量知

识库，用于提升生成式人工智能准确性和可靠性的技术。具体而言，在大模型生成内容时，RAG将首先在外部知识库中检索相关信息，随后依据相关信息大模型将生成更为准确的回答。基于可随时更新的外部知识库，RAG在有效提升大模型生成内容的时效性与准确性的同时，降低了大模型产生“幻觉”现象的可能性。对于代码复现系统，RAG能支撑海量文档并提供高效信息检索，为代码生成提供信息依据。

“GPT如海”可复现因子计算和人工智能量化策略代码

我们针对不同应用场景设计了两套代码复现模板，分别是因子代码复现和人工智能量化策略代码复现。对于因子代码复现场景，测试结果显示“GPT如海”能够较准确地提取出图片或PDF文档中的因子表达式以及因子构建步骤，并能进一步以此为基础构建因子计算代码；对于人工智能量化策略复现场景，测试结果显示，“GPT如海”能够较准确地提取出人工智能量化策略的构建步骤和细节参数，并依次输出数据集构建、模型架构和模型训练的.py代码，在代码细节上，我们观察到“GPT如海”能够敏锐捕捉到策略构建的细节，例如损失函数设计等，尽管这些细节信息散布在文章各处。

多模型复现效果对比：小模型也可“纳须弥于芥子”

在大模型如火如荼的发展进程中，专为响应大模型落地需求的小型大语言模型也渐为兴盛。我们简易对比了GPT-4、通义千问（Qwen 1.5, 7B）和Llama3（8B）的代码生成效果，在不同评价维度上，三个模型展现出差异性特征，例如GPT-4并不严格遵守代码模板，而通义千问和Llama3较为遵守代码模板。客观而言，通义千问和Llama3以小参数体量博得不错的代码生成效果，体现出小型模型“纳须弥于芥子”的潜力。

风险提示：大模型存在幻觉现象，模型生成结果可能不符合事实。大模型生成的代码可能存在错误，使用需谨慎。大模型提取信息可能存在遗漏。大模型训练集广泛，可能存在过拟合风险。

正文

01 导言

“善学者，其如海乎” ——《随园诗话·补遗 卷四》

自OpenAI推出ChatGPT以来，大语言模型（Large Language Model，LLM）强大的指令遵循、语义理解、内容生成等能力屡屡超出预期，在办公、编程、游戏等多个领域带来革命性进展。与此同时，多模态大语言模型（Multimodal Large Language Model，MLLM）将视觉（图像）、听觉（语音）感知和文本理解相结合，展现出更加广阔的应用前景。在华泰金工前期研究《GPT因子工厂：多智能体与因子挖掘》（2024年2月20日）中，我们利用基于大模型的多智能体系统实现端到端的量价因子挖掘系统，在因子构建、逻辑解释、代码生成等方面表现出色，展现出大语言模型赋能量化研究的潜力。

本文将继续探索多模态大模型和RAG（Retrieval-Augmented Generation，检索增强生成）技术在量化研究中的应用。量化研究中多模态数据丰富，包括且不限于文本和图像等。以往的深度学习通常只能处理单一模态的数据，应用范围较为有限；多模态大模型则可以同时从多模态多类型的数据中抽取信息，显著提高模型的感知范围，在量化研究领域可能具有广阔的应用潜力。但另一方面，量化研究领域对内容的时效性、准确性有很高要求，而目前大模型的参数难以实时更新，并且生成的内容可能含有事实性错误，极大地限制了大模型在量化领域的应用。

RAG技术可能成为大模型应用于量化研究领域的破局关键。RAG技术可以从外部知识库中检索相关知识，辅助大模型生成内容，不仅极大地缓解了模型的幻觉现象，而且省去了微调大模型的昂贵成本。结合金融领域沉淀的丰富数据，检索增强生成技术适用于多种生成式任务，例如智能问答、综述总结、股票预测等，具有广阔的应用前景。

本文主要探究多模态大模型和RAG技术在代码复现中的应用。在量化研究领域，研究者通常需要广泛地阅读和学习海量研究报告，从中收集信息、汲取灵感，提高自身研究能力。然而，复现量化研究报告相关的代码往往较为复杂，不仅包含文本信息、图像信息的理解和处理，还包括处理数据、撰写代码等多个步骤。我们希望借助多模态大模型在图像感知、语义理解、代码生成等能力，结合RAG技术的准确性和可靠性，辅助研究员复现研究报告，提高复现效率。本研究基于OpenAI的GPT-4系列模型，通过检索增强生成的方式，将量化研究报告中的因子或人工智能量化策略转化为.py代码文件，有效降低代码复现工作的复杂度，大幅提升工作效率。

图表1：华泰金工-GPT 复现因子研报 WebUI 界面




资料来源：Embedchain, Streamlit, OpenAI, 华泰研究

02 多模态大语言模型

传统的神经网络仅能处理单一模态的数据，如视觉图像、文本、音频等。然而，人类在和外界环境交互时通常需要同时处理多种模态的信息，进而能更准确地感知、理解、决策。以研究报告为例，其中的图表能够直观准确地展现时序趋势或者条件比较等信息，这是文字和数字难以表述的。因此，为人工智能模型赋予多模态感知和生成能力，可能是实现通用人工智能（Artificial General Intelligence，AGI）的必由之路。

过去三年中，多模态大模型得到了长足的发展。OpenAI于2021年提出CLIP模型，实现了文本数据和图像数据之间的映射。CLIP模型不仅可以识别图像类型，而且可以生成图像、搜索与文本对应的图像，成为了目前多模态大语言模型的基石。DeepMind在2022年推出Flamingo模型，将预训练视觉模型和语言模型相连接，使得大语言模型能够同时理解视觉和文本信息，并生成文本输出。2023年10月，OpenAI推出多模态大语言模型GPT-4-Vision，其展现出强大的多模态感知能力和多任务能力。GPT-4-Vision可以从图表中找到用户需要的数据，也可以回答图片相关的问题。除了将视觉信息融入大语言模型以外，研究者们还将语音信息和大语言模型相结合。目前，多模态大模型已经具备同时感知文本、图像、音频的能力，并且逐渐发展出生成多模态内容的能力。


图表2：多模态大语言模型 GPT-4-vision 能力测试示例



资料来源：The Dawn of LLMs: Preliminary Explorations with GPT-4V(vision)，华泰研究

多模态大模型已经成为人工智能发展的趋势，具有广阔的应用前景。多模态大模型在多种模态的感知和理解能力的加持下，可以从多模态数据中获取更为全面综合的信息，显著提高模型性能。此外，多模态大模型的多模态输入和输出能力使得人与模型的交互更加灵活多样，落地应用场景也更丰富多元，有望赋能娱乐、医疗、电商、游戏、金融等诸多领域。

图表3：多模态大语言模型发展时间线



资料来源：MM-LLMs: Recent Advances in Multimodal Large Language Models，华泰研究


在量化研究领域中，研究报告同样蕴含较为丰富的多模态数据，包括文本和图像数据。通常意义上的大语言模型只能处理文本数据，却无法提取报告中以图表形式呈现的信息，因此在研究报告复现上可能具有较大的局限性。因此，本研究尝试借助多模态大模型的图像感知能力，助力研究报告相关代码的复现工程。

尽管如此，仅靠多模态大模型自身仍然难以完成这一任务。一方面，目前的主流多模态大模型的上下文长度有限，难以将研究报告文件直接作为模型输入；另一方面，GPT-4等支持长文本输入的模型难以从量化研究报告中捕捉重点信息和复现细节，生成内容的质量可能不尽人意。因此，我们在多模态大模型的基础上，尝试叠加RAG（检索增强生成）技术，从而显著提高模型的复现质量。

03 RAG：检索增强生成

RAG（Retrieval-Augmented Generation，检索增强生成）是一种通过使用外部来源获得的事实，用于提升生成式人工智能准确性和可靠性的技术。虽然目前大模型展现出很强的生成能力，但由于其训练数据和模型结构的局限性，生成的内容往往并不准确甚至脱离现实，也即幻觉（Hallucination）现象的主要来源之一。为了提高大模型生成内容的时效性、准确性，研究者们提出了RAG方法，已有研究者如Peng et al. (2023)的研究显示出检索增强能有效降低幻觉现象。

图表4：检索增强生成技术进化树




资料来源：Retrieval-Augmented Generation for Large Language Models: A Survey, 华泰研究

具体而言，RAG是指在大模型生成内容时，首先在外库知识库中检索相关信息，然后再根据相关信息生成回答的技术。经典的检索增强生成技术包括三个步骤，分别是索引（Indexing）、检索（Retrieval）和生成（Generation）：

1. **索引（Indexing）**：构建外部知识库的过程。首先需要收集任务相关的文本数据；然后将这些文本数据切分为更小的块（Chunk），以便适配大模型的输入长度；最后进行嵌入和索引。具体而言，嵌入模型（Embedding Model）将文本段落编码映射为固定长度的向量，并利用嵌入向量和文本段落建立起键值对，储存在向量数据库中，形成索引。
2. **检索（Retrieval）**：根据用户输入的问题检索相关的外部知识。首先利用嵌入模型将用户的问题映射为嵌入向量；然后和外部数据库中的嵌入向量计算相似性，将相似性最高的K个嵌入向量对应的文本块作为当前问题的补充信息。
3. **生成（Generation）**：大模型根据用户指令和补充信息生成最终结果。系统将检索得到的K条文本段落和用户的问题合并为新的提示信息，将其作为大模型的输入并得到最终的结果。

图表5：RAG 应用架构示意图



RAG使得模型不仅可以利用其内部知识，还可以利用外部知识辅助生成。其优点在于：

1. 不需要微调大模型，大大降低了使用成本；
2. 不同的知识库可以适配不同的任务，同时知识库可以不断更新，更加动态灵活
3. 大模型生成的答案可以追溯到具体的数据来源，具有更强的可追溯性和可靠性。因此，检索增强生成是大模型落地应用的关键技术之一。为了准确复现报告中涉及的代码，我们采用RAG技术，先从图片或文档中检索因子或人工智能量化策略相关信息，再由大模型进行复现。


RAG vs Fine-tuning

在构建大语言模型应用程序时，我们通常可使用两种方式整合特定领域的知识：RAG和微调（Fine-tuning）。RAG与微调各有其优势，我们可以从外部知识需求和模型适应性需求两个维度进行对比：

1. **外部知识需求方面**：构建外部知识库的过程。首先需要收集任务相关的文本数据；然后将这些文本数据切分为更小的块（Chunk），以便适配大模型的输入长度；最后进行嵌入和索引。具体而言，嵌入模型（Embedding Model）将文本段落编码映射为固定长度的向量，并利用嵌入向量和文本段落建立起键值对，储存在向量数据库中，形成索引。
2. **检索（Retrieval）**：根据用户输入的问题检索相关的外部知识。首先利用嵌入模型将用户的问题映射为嵌入向量；然后和外部数据库中的嵌入向量计算相似性，将相似性最高的K个嵌入向量对应的文本块作为当前问题的补充信息。

但RAG和微调技术并非针锋相对或水火不容，同时结合RAG和微调技术可能会创造出既具有广泛知识又拥有特定领域专长的大模型应用。举例而言，Zhang et al. (2024)提出RAFT（Retrieval-Augmented Fine-Tuning，检索增强型微调）的技术，通过构造有价值文档和干扰文档数据集对大模型进行微调，从而使得大模型能够更好地执行RAG，提升其通过检索和推理回答问题的能力。

图表6：RAG 与微调技术的对比



RAG实现：检索增强生成开源框架Embedchain

Embedchain是一个用于实现RAG架构的轻量级开源框架，专注于快速搭建基于RAG的大模型问答系统。该框架集成了加载数据、创建嵌入向量、向量数据库存储和相似度检索等多项功能，不仅可以处理各种非结构化数据，包括文本、PDF文件、网页、图像、视频等，还可以无缝衔接主流的大模型，包括OpenAI的GPT系列、Meta的Llama系列和Anthropic的Claude系列模型等。除此之外，基于Embedchain构建的应用可以轻松通过Streamlit和Gradio等框架进行部署。本研究依赖于Embedchain框架，搭建RAG系统并使用Streamlit进行部署。

图表7：Embedchain 框架的文件及模型支持



04 方法

本研究基于多模态大模型和RAG技术进行代码复现，可实现从图片和PDF文件等多模态数据中获得因子构建信息或人工智能量化策略，并直接生成对应的.py代码文件，实现端到端的代码复现流程。本系统遵循基本的RAG架构，分为四个步骤，分别是索引、检索、生成以及最终的部署。

索引 (Indexing)

索引阶段负责根据量化研究报告构建外部知识库。首先，系统会根据用户输入的文件格式进行数据预处理，将多模态的数据输入统一转换为文本数据。如PDF格式的文件会被解析为文本部分和图片

部分，而图片部分会通过GPT-4 vision模型转换为文本描述；若单独输入图片格式的文件，同样会经此处理。随后，预处理所得的文本数据会被分割为相同大小的块，并通过OpenAI的嵌入模型text-embedding-3-large转化为相同长度的向量，存储至向量数据库中。

检索 (Retrieval)

检索阶段负责从外部知识库中检索相关知识。为了精确复现代码，我们将复现步骤进一步细化，例如复现人工智能量化策略被细分为“输入和输出数据”“数据预处理方法”“网络结构”“训练参数”四个步骤，每个步骤都有对应的查询语句。在检索时，查询语句先由嵌入模型映射为向量，然后与向量数据库中的向量计算相似度。相似度最高的K个向量对应的文本块会作为该复现步骤的相关内容，辅助模型生成。

生成 (Generation)

生成阶段分为三个阶段：（1）首先，检索阶段获得的查询语句和相关知识会输入大模型，由模型总结生成对应的研究报告细节，如神经网络类因子的数据、结构、参数等；（2）其次，我们设计了“自我反思”环节。我们将第一步获得的报告细节输入大模型，让模型对目前的复现内容进行反思，生成进一步的优化建议，从而辅助研究员阅读研究报告、改进复现代码；（3）最后，系统将自然语言格式的复现细节输入大模型，由模型生成各个复现步骤对应的代码文件。为了提高代码质量，我们设计了代码模版，辅助模型生成。由此，我们实现了基于多模态大模型和RAG的量化代码复现系统，我们为它起了一个有趣的名字：GPT如海，寓意其善学如海。

图表8：基于多模态大模型和 RAG 的代码复现系统具体参数

步骤	参数	参数值
索引	块大小/块间重叠大小	500/200
	多模态大模型	gpt-4-vision-preview
	嵌入模型	text-embedding-3-large
	向量数据库	Chroma
	嵌入向量长度	1536
检索	相似度度量	余弦相似度
	K	15
生成	大模型	如无特殊说明，默认为 gpt-4-0125-preview

资料来源：华泰研究

部署(Deployment)

“GPT如海”构建完毕后，我们基于Streamlit框架将整个系统部署于本地HTTP端口，通过本地localhost（默认8501端口）即可轻松访问，既方便文件上传，也便于生成代码后直接下载。

05 结果

对于“GPT如海”系统，我们一共设计了两个版本，其一专门用于复现图片或PDF文档中涉及的量化因子，其二则用于复现图片或PDF文档中的人工智能量化策略，二者在界面和使用上几乎没有差异。以下我们将通过界面展示和代码功能展示对“GPT如海”进行更为详尽的展示。


WebUI主要功能

在部署完毕的“GPT如海”系统中，关于代码复现的各项功能已趋于完善。系统运行严格遵循以下 workflow：

- 1. **填入大模型API**：填入OpenAI或其他可调用模型的API，以供代码复现系统生成代码；
- 2. **上传文件**：支持图片或PDF格式文件上传，可上传多个文件；
- 3. **开始复现**：点击 Start 按钮代码复现系统即开始运转，无需自行输入或设定提示 (Prompt) ；

4. **因子信息提取**：系统中大模型将从RAG架构中的向量数据库提取复现代码所需信息，例如因子表达式和因子构建步骤，并将其输出，便于人工监督检查；
5. **代码复现**：大模型输出的代码将以代码风格展示（仅支持Python代码），便于阅读；
6. **代码文件下载**：点击代码旁的Download可直接将.py文件下载至本地。

图表9：WebUI界面功能解析（因子代码复现）




资料来源：Embedchain, Streamlit, OpenAI, 华泰研究

因子计算代码复现

首先我们测试“GPT如海”系统的因子代码复现能力。本文尝试向系统输入一张用手机拍摄的.jpg格式照片（像素大小为2268×4032），图片中包含一个较复杂量价选股因子的表达式和解析。从大模型输出中可以看到，“GPT如海”可以从具备噪音（如阴影、褶皱等）的图片中准确无误地提取出因子数学表达式，并使用Latex输出，显示出其依赖的多模态大模型（即gpt-4-vision-preview）的多模态信息提取能力。随后，“GPT如海”输出该因子的计算代码，从代码上看，复现代码基本符合因子构建步骤。

图表10：单因子代码复现（图像文件输入）




资料来源：Embedchain, Streamlit, OpenAI, 量化投资与机器学习, 华泰研究

对于因子复现版本的“GPT如海”，其同样支持多个因子的信息提取与代码复现。在华泰金工前期报告《析精剖微：机构拆解看北向资金》（2022年10月27日）中，我们定义了4类可用于行业配置的

北向因子：持仓市值因子、资金流向因子、主动权重因子和机构打分因子，但最终构建行业配置策略时由于主动权重因子与其他因子相关性较高，只纳入了其余3个因子。当我们将完整的38页数据输入复现系统后，“GPT如海”成功提取用于构建策略的3个因子相关信息，并依次生成3个因子的.py计算代码，显著表明多模态大模型对表格图片的理解，以及RAG系统加持下大模型的信息提取能力和代码生成能力。

图表11：多因子代码复现（PDF文件输入）




人工智能量化策略代码复现

除因子复现外，“GPT如海”还可进行人工智能量化策略代码的复现。随量化研究领域的日益发展，量化模型渐趋复杂，人工智能技术的应用也愈发广泛，在学习公开论文或研究报告时难免需要复现相关代码。对于一个较完善的人工智能策略而言，可能包含诸多组成部分，包括数据集构建、模型架构搭建和模型训练评估等等，在良好代码能力的基础上想要复现也是一件需花费颇多精力的事情。


华泰金工团队已公开发布70余篇人工智能相关研报，我们选取其中两篇让“GPT如海”尝试复现。第一篇报告为华泰金工人工智能系列第71篇：《自适应网络：从削足适履到量体裁衣》（2023年12月1日），此篇报告主要探究动态自适应网络架构能否在传统网络的基础上带来效果提升，其中动态自适应网络概念繁杂、变体众多，相关代码的实现可能具备一定难度。我们直接将25页原始PDF文档输入复现系统，“GPT如海”可逐步提取出因子数据集、数据预处理、训练参数、神经网络架构等策略相关信息，同时进行自我反思，用于判断复现依赖信息的缺失与否。信息提取完毕后，“GPT如海”依次生成数据集构建、模型架构和模型训练的3个.py代码。

图表12：人工智能量化策略代码复现示例一（PDF文件输入）



我们可详细观察“GPT如海”代码复现的特点。对于代码注释而言，注释丰富鲜明，表达上也较为谨慎，有效提升了代码的可读性和可参考性；对于原文核心信息捕捉上，“GPT如海”复现系统也较为准确，例如原文强调神经网络架构的整体损失为主干网络和门控网络的合成，复现代码中也的确书写正确，但“GPT如海”也并非没有错误，例如主干网络的损失实际是收益率衰减加权的mse损失，但它写为交叉熵损失（代码第22行）；在代码准确性上，我们发现“GPT如海”依赖的gpt-4-0125-preview模型能力较强，无论是神经网络的反向传播、类的撰写以及函数的调用等等都较为准确，表明该系统的代码复现水平较高。


图表13：人工智能量化策略代码复现示例一中的代码亮点（以训练代码为例）



资料来源：Embedchain, Streamlit, OpenAI, 华泰研究

第二篇测试人工智能量化策略代码的文章为华泰金工人工智能系列第72篇：《基于全频段量价特征的选股模型》（2023年12月8日），此篇报告聚焦于高频和低频量价数据的信息挖掘，基于多频段量价数据构建了一个端到端神经网络选股模型。我们将27页原始PDF文档输入“GPT如海”复现系统，策略相关信息同样被稳定提取出来，“GPT如海”根据这些信息依次生成数据集和神经网络相关代码。

图表14：人工智能量化策略代码复现示例二（PDF 文件输入）



资料来源：Embedchain, Streamlit, OpenAI, 华泰研究


多模型测试：代码复现效果对比

随着大语言模型的发展，大模型的终端落地需求逐步推动小型模型的开发迭代进程，迄今已有一批较出色的小型大语言模型脱颖而出，例如阿里巴巴公司推出的开源大模型通义千问、Meta公司推

出的Llama系列开源大模型。小型模型部署便利、输出速度较快的优势使得个人能够以较低廉的成本部署使用大语言模型。为检验小型模型在代码复现上的效果，我们选择两个开源模型与GPT-4进行对比，模型分别为7B参数量的Qwen 1.5和8B参数量的Llama3。在对比测试中，“GPT如海”除生成代码的模型改为Qwen 1.5或Llama3，其余设置均不变。

我们测试了如图表10中的单因子图片输入，三个模型输出的代码复现结果如下图所示。简单从输出代码行数上看，GPT-4输出的代码行数最多，Llama3次之，通义千问输出的代码长度最短。

图表 15：多模型代码复现效果对比



资料来源：Embedchain, Streamlit, OpenAI, HuggingFace, LM-Studio, 华泰研究

我们详细解读三份代码，可以发现三个模型在不同维度上显示出不同特点。在代码能否直接运行方面，仅有GPT-4输出的代码可以直接运行，而通义千问和Llama3输出的代码均会报错；在代码正确情况下，我们详细阅读了三份代码，发现或多或少都存在一些错误，但GPT-4的错误是最少的，几乎接近正确答案；在是否遵循代码模板方面，通义千问和Llama3均在遵守模板的情况下生成了代码，而GPT-4与模板略有不同，增加了一个因子项的计算函数；在注释丰富程度上，GPT-4和通义千问均较丰富，Llama3的注释则简单不少。值得强调的是，以上对比仅为简易探索，且仅进行了一次代码生成测试，可能不具备结论性，评价维度与内容也较为主观，作为个人观点仅供参考。

图表 16：多模型代码复现效果对比详细信息

	GPT-4	通义千问	Llama3
模型全称	gpt-4-0125-preview	Qwen1.5-7B-Chat	Llama3-8B-Chinese-Chat
参数量	-	7B	8B
来源	OpenAI	Hugging Face: Qwen/Qwen1.5-7B-Chat-GGUF	Hugging Face: shenzhi-wang/Llama3-8B-Chinese-Chat-GGUF-8bit
代码能否直接运行	是	否	否
代码正确情况	少量错误	部分正确	部分正确
是否遵循代码模板	否	是	是
注释丰富程度	丰富	丰富	一般
模型运行环境	联网 api 调用	本地运行	本地运行
模型来源	OpenAI	Hugging Face: Qwen/Qwen1.5-7B-Chat-GGUF	Hugging Face: shenzhi-wang/Llama3-8B-Chinese-Chat-GGUF-8bit

资料来源：OpenAI, HuggingFace, LM-Studio, 华泰研究

06 总结

本文在华泰金工前期研究《GPT因子工厂：多智能体与因子挖掘》（2024年2月20日）的基础上，继续探索大语言模型在量化研究领域的潜在应用。以代码复现需求为切入点，我们基于多模态大模型和RAG技术构建了一个完善易用的代码复现框架，“GPT如海”。在框架内部，“GPT如海”既依赖

于多模态大模型对于不同模态信息的提取能力，也离不开RAG技术对海量文档的检索支持，最终使得基本的GPT-4模型在应用框架的加持下发挥出了极为出色的代码复现效果。

我们针对不同应用场景设计了两套代码复现模板，分别是因子代码复现和人工智能量化策略代码复现。对于因子代码复现场景，我们尝试向系统输入包含因子构建信息的图片或PDF文档，测试结果显示“GPT如海”能够较准确地提取出图片或PDF文档中的因子表达式以及因子构建步骤，并能进一步以此为基础构建因子计算代码；除此之外，如果PDF文档中包含多个因子，即使因子信息分散在不同文段，“GPT如海”也能有效检索，并逐个输出因子代码。

对于人工智能量化策略复现场景，我们向系统输入两篇华泰金工人工智能深度报告：《自适应网络：从削足适履到量体裁衣》（2023年12月1日）和《基于全频率量价特征的选股模型》（2023年12月8日）。测试结果显示，“GPT如海”能够较准确地提取人工智能量化策略的构建步骤和细节参数，并依次输出数据集构建、模型架构和模型训练的.py代码。在代码细节上，我们观察到“GPT如海”敏锐捕捉到策略构建的细节，例如损失函数设计等，尽管这些细节信息散布在文章各处。

在大模型如火如荼的发展进程中，专为响应大模型落地需求的小型大语言模型也渐为兴盛。我们简要对比了GPT-4、通义千问（Qwen 1.5, 7B）和Llama3（8B）的代码生成效果，在不同评价维度上，三个模型展现出差异性的特征，例如GPT-4并不严格遵守代码模板，而通义千问和Llama3较为遵守代码模板。不过对比结果仅依赖于单次代码生成，不具备结论性，仅供参考。

本文作为大语言模型在量化研究领域代码复现场景下的应用探索，搭建的“GPT如海”工具已趋于完善，但仍有诸多不足之处。例如，“GPT如海”系统效果不稳定，有时无法提取出因子信息或提取信息有误；作为大语言模型为基础的应用系统，“GPT如海”内部的提示工程仍存在可提升之处；此外，WebUI部署设计较为简单，值得进一步优化。

参考资料

Yang, Z., Li, L., Lin, K., Wang, J., Lin, C. C., Liu, Z., & Wang, L. (2023). The dawn of Imms: Preliminary explorations with gpt-4v (ision). arXiv preprint arXiv:2309.17421, 9(1), 1.

Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., ... & Wang, H. (2023). Retrieval-augmented generation for large language models: A survey. arXiv preprint arXiv:2312.10997.

Peng, B., Galley, M., He, P., Cheng, H., Xie, Y., Hu, Y., ... & Gao, J. (2023). Check your facts and try again: Improving large language models with external knowledge and automated feedback. arXiv preprint arXiv:2302.12813.

Zhang, D., Yu, Y., Li, C., Dong, J., Su, D., Chu, C., & Yu, D. (2024). Mm-llms: Recent advances in multimodal large language models. arXiv preprint arXiv:2401.13601.

风险提示

大模型存在幻觉现象，模型生成结果可能不符合事实。大模型生成的代码可能存在错误，使用需谨慎。大模型提取信息可能存在遗漏。大模型训练集广泛，可能存在过拟合风险。

相关研报

研报：《 金工：“GPT如海”：RAG与代码复现》2024年5月06日
分析师：林晓明 S0570516010001 | BPY421
分析师：何康 S0570520080004 | BRB318
联系人：沈洋 S0570123070271

关注我们



华泰证券金融工程
主要进行量化投资相关的研究和讨论工作。
427篇原创内容

公众号

华泰证券研究所国内站（研究Portal）

<https://inst.htsc.com/research>

访问权限：国内机构客户

华泰证券研究所海外站

<https://intl.inst.htsc.com/research>

访问权限：美国及香港金控机构客户
添加权限请联系您的华泰对口客户经理

免责声明

▲向上滑动阅览

分析师声明

本人，林晓明、何康，兹证明本报告所表达的观点准确地反映了分析师对标的证券或发行人的个人意见；彼以往、现在或未来并无就其研究报告所提供的具体建议或所表达的意见直接或间接收取任何报酬。

一般声明及披露

本报告由华泰证券股份有限公司（已具备中国证监会批准的证券投资咨询业务资格，以下简称“本公司”）制作。本报告所载资料是仅供接收人的严格保密资料。本报告仅供本公司及其客户和其关联机构使用。本公司不因接收人收到本报告而视其为客户。

本报告基于本公司认为可靠的、已公开的信息编制，但本公司及其关联机构(以下统称为“华泰”)对该等信息的准确性及完整性不作任何保证。

人工智能 25

人工智能 · 目录

上一篇

华泰金工 | GPT因子工厂：多智能体与因子挖掘

下一篇

华泰金工 | 多任务学习选股模型的改进

个人观点，仅供参考