

端到端的动态 Alpha 模型

量化选股策略

——AI 系列研究之一

本文提出了一种基于深度神经网络的动态 Alpha 因子模型，实现了端到端的因子权重训练和预期收益率预测。在 IC、ICIR、因子分组收益率、多头组合收益率等指标维度表现相比于线性 Alpha 因子模型有较为明显的提升。

- 传统线性因子模型存在一定的缺陷。无套利条件中随机折现因子的线性结构学术界尚存在争论。实证研究中，残差的时序和截面的相关性以及残差的异方差性在线性因子模型中，通常需要特殊的手段处理。在因子模型中引入非线性成为学术界和业界的主流做法。
- 基于 MLP 的因子网络结构，相比于 L2 正则的线性基准网络，在 RankIC 均值略有下降。多空年化收益率、多空夏普等指标改善明显。多头收益率对 RankIC 的贡献提升。
- 借鉴传统的 Alpha 模型，细分因子到大类因子分步合成，一般需要筛选出 IC 表现较好，且相关性较低的细分因子合成大类因子，以保证大类因子的 IC 表现和低相关性。在 MLP 网络中同样可以引入正交惩罚使得网络学习到的大类因子保持低相关性。
- 在机器学习任务中，不同学习目标的设置同样对模型的表现有至关重要的影响。本文测试了使用 MSE、IC、CCC 不同的损失函数对模型表现的影响。IC 损失函数的综合表现最好。CCC 损失函数对应的模型的合成 zscore 因子稳定性最好。
- 本文的研究过程发现 IC 作为传统的单因子表现指标，在多头选股的场景下并不能正确评估最终的选股表现。需要结合因子的多空最大回撤、多空夏普以及多头组合的表现来综合评估。
- 风险提示：量化策略基于历史数据统计，模型存在失效的可能性。

任瞳 S1090519080004
rentong@cmschina.com.cn
周靖明 S1090519080007
zhoujingming@cmschina.com.cn
周游 研究助理
zhouyou4@cmschina.com.cn

正文目录

一、传统因子投资框架	4
1.1. 多因子 Alpha 模型构建流程	4
1.2. 当前因子模型遇到的问题	5
二、引入非线性的 Alpha 模型	7
2.1. 线性基准网络	8
2.2. 非线性 Alpha 网络	10
2.3. 因子正交化正则	13
2.4. 优化目标的改进	14
2.5. 模型分析	16
2.5. 在不同成分股中的选股效果	18
三、总结	18
附录：本文所使用的部分因子说明	21

图表目录

图 1：多因子 Alpha 模型构建流程	4
图 2：组合优化流程	4
图 3：常见量化策略类型	4
图 4：BP 因子多空净值（20110901-20230401）	5
图 5：BP 因子月度 RankIC（20110901-20230401）	5
图 6：BP 因子多头日渐拥挤（20110901-20230401）	6
图 7：中性化后 AR 因子分组历史走势（20110901-20230401）	6
图 8：AR 因子多空净值走势（20160401-20230401）	7
图 9：AR 因子组内多空收益率分布	7
图 10：数据集划分说明	8
图 11：线性 Alpha 网络结构	9
图 12：线性 Alpha 模型 RankIC 走势图	9
图 13：分组年化基准对冲收益（20160401-20230401）	9
图 14：线性 Alpha 模型多头等权策略历史表现	10
图 15：非线性 Alpha 网络结构	11

图 16: ReLU vs Sigmoid 激活函数.....	11
图 17: 非线性 Alpha 模型 RankIC 走势图 (MLP)	11
图 18: 分组年化基准对冲收益 (20160401-20230401, MLP)	11
图 19: 非线性 Alpha 模型多头等权策略历史表现 (MLP+MSE 损失)	12
图 20: 加入正交惩罚的 MLP 因子网络	13
图 21: 正则化 MLP 的 zscore 分组对冲基准年化收益.....	13
图 22: 非线性 Alpha 模型 RankIC 走势图 (MLP+正交惩罚+MSE 损失)	14
图 23: MLP 网络不同损失函数分组对冲基准年化收益率 (正则化)	15
图 24: 不同模型的多空净值历史表现 (20160401-20230401)	16
图 25: 不同模型多头等权组合历史表现 (20160401-20230401)	16
图 26: 特征重要性示意图 (SHAP 归因)	17
图 27: 特征对模型输出的平均影响 (SHAP 归因)	17
图 28: 模型在不同成分股中的对冲基准年化收益率 (20160401-20230401)	18
表 1: 模型固定参数说明	8
表 2: MLP 网络参数设置	10
表 3: MLP 模型与基准线性模型合成因子表现对比	12
表 4: MLP 与基准线性模型多头等权策略表现对比	12
表 5: 加入正交惩罚项后合成 zscore 的表现对比	14
表 6: 不同模型合成 zscore 表现对比.....	15
表 7: 模型 zscore 与常见风格因子的平均截面相关性 (20160401-20230401)	17
表 8: 模型在不同成分股中选股的表现	18
表 9: 因子说明	21

一、传统因子投资框架


1.1. 多因子 Alpha 模型构建流程

传统因子投资框架，在业界已得到广泛的应用。从模块划分，主要包括 Alpha 模型、风险模型、组合优化、交易执行等模块。其中风险模型相对成熟、业界常用 BARRA 因子作为风险估计模型，或者在其基础上定制。本文主要讨论收益预测模型，即 Alpha 模型。收益预测的步骤主要包括：

- 1) 数据清洗
- 2) 因子构建，极端值处理
- 3) 因子分类、大类因子合成
- 4) 大类因子权重组合
- 5) 收益预测


等步骤。其中因子构建步骤、大类因子合成、通常使用回归法及其变种，例如 LASSO、岭回归等方式来降低细分因子或者大类因子之间的共线性。

图 1：多因子 Alpha 模型构建流程




资料来源：招商证券

图 2：组合优化流程



资料来源：招商证券

图 3：常见量化策略类型



资料来源：招商证券

传统因子投资框架日趋成熟，但该框架中存在的问题仍然有诸多争议。在本文的后续章节中将重点讨论并尝试

解决这些问题。

1.2. 当前因子模型遇到的问题

传统因子投资流程中，线性回归的方法运用广泛。从缺失值处理到因子有效性分析到最终的因子组合，都用到了线性回归的方法。但因子收益率与资产收益率的线性关系并不一定成立。线性因子模型的理论基础是 APT 定价模型，APT 的无套利假设使得 $t+1$ 时刻的资产收益率 $r_{i,t+1}$ 满足：

$$E_t[m_{t+1}r_{i,t+1}] = 0 \Leftrightarrow E_t[r_{i,t+1}] = \frac{\text{Cov}_t(m_{t+1}, r_{i,t+1})}{\text{Var}_t(m_{t+1})} \frac{\text{Var}_t(m_{t+1})}{E_t[m_{t+1}]}$$

记第一项为 $\beta'_{i,t}$ ，第二项为 λ_t ，当 m_{t+1} 满足线性结构时， $t+1$ 时刻的资产收益率 $r_{i,t+1}$ 的资产定价模型为：

$$r_{i,t+1} = \alpha_{i,t} + \beta'_{i,t} f_{t+1} + \epsilon_{i,t+1}$$

其中， $E_t(\epsilon_{i,t+1}) = E_t[\epsilon_{i,t+1} f_{t+1}] = 0$ ， $E_t[f_{t+1}] = \lambda_t$ ，在该线性结构的假设下，估计因子收益率 λ_t 需要满足上述的高斯马尔可夫定律。但在实际金融数据中，残差的异方差性、残差的时序相关性以及截面相关性并不满足为 0。因此在实际因子模型构建的过程中通常会使用很多的统计手段来减少线性假设带来的问题。例如，使用 Fama-Macbeth 回归来减少残差的截面相关性。Barra 风险模型，使用股票总市值倒数的根作为权重来进行 WLS 回归来减轻残差的异方差性。综上，因子模型的线性结构存在诸多问题，线性结构并不是标准答案。


在实证因子投资的过程中，业界早已开始引入非线性因子。例如，BARRA CNE6 模型中 SIZE 风格因子的构建过程中，其中一个细分因子为非线性因子 *midcap*，构建过程为：

$$\begin{aligned} \text{size}_i &= \ln(\text{market_cap}) \\ \text{midcap}_i &= \text{size}_i^3 - a - b * \text{size}_i \end{aligned}$$

即总市值的三次方对原 size 因子 ($\ln(\text{size})$) WLS 回归后的残差作为非线性市值因子，该 WLS 有显式解，*midcap* 因子可以看作 $f(\text{size})$ ，其中 f 为非线性函数。

上述例子说明了线性因子模型在理论上存在一定的缺陷。在当今业界，由于因子同质化，和多因子策略的同质化导致传统因子日渐拥挤。以 BP 因子为例，在 2019，2020 两年几乎失效。

图 4: BP 因子多空净值 (20110901-20230401)



资料来源：招商证券


图 5: BP 因子月度 RankIC (20110901-20230401)

	1	2	3	4	5	6	7	8	9	10	11	12
2011									0.1	-0.05	0.033	0.16
2012	0.063	0.0062	0.039	0.034	-0.0024	-0.035	-0.0039	0.05	0.05	0.14	0.12	-0.04
2013	-0.00065	-0.089	-0.056	-0.098	-0.064	-0.11	0.072	0.15	0.04	0.077	0.14	-0.12
2014	-0.0028	0.14	0.15	0.024	-0.065	0.14	0.12	0.066	0.12	0.14	0.18	0.071
2015	-0.095	0.00092	0.1	-0.067	0.13	0.13	0.16	0.042	0.021	0.0041	0.062	0.14
2016	0.019	0.17	-0.0098	0.054	0.01	0.15	0.21	0.088	0.034	0.099	0.15	0.19
2017	0.15	-0.002	0.077	-0.051	0.052	0.16	0.14	-0.032	-0.051	-0.056	0.048	0.11
2018	0.035	-0.067	0.083	-0.04	-0.026	0.015	0.25	0.12	-0.0038	0.14	0.036	0.11
2019	0.06	0.098	0.1	-0.021	-0.025	0.02	-0.11	-0.032	-0.0071	0.012	0.078	0.0079
2020	-0.067	0.11	-0.023	-0.15	-0.074	-0.014	0.083	0.097	-0.07	0.14	0.093	0.012
2021	0.096	0.24	0.014	0.029	-0.087	0.019	0.063	0.25	-0.07	-0.11	0.14	0.24
2022	0.13	0.05	0.18	-0.077	-0.081	-0.013	0.029	0.13	0.018	0.03	0.15	-0.056
2023	0.14	0.22	0.12									

资料来源：招商证券

从分组收益率更能看出因子在实际投资过程中的表现。由于卖空限制的存在，多头收益率更能反应出因子的实际表现。在 2021 年后，BP 因子的月度 RankIC 仍然有不错的表现，但 IC 基本由空头贡献。BP 因子日渐拥挤。

图 6：BP 因子多头日渐拥挤（20110901-20230401）



资料来源：Wind、招商证券

以技术指标为代表的量价因子的 IC 贡献中空头贡献占比较高。多头拥挤现象已经存在已久。这里以人气意愿指标 AR（技术指标）为例，该指标反应了日内买卖意愿的强弱。

$$AR = \frac{\sum(HIGH - OPEN, M1)}{\sum(OPEN - LOW, M1)} * 100, M1 = 26$$

在过去 7 年内，20 日调仓的平均 RankIC 约为 0.058，IC 的 t 值为 32.75，未年化 IR 为 0.79，IC 胜率为 79%，从指标上来看是一个显著有效的因子。

图 7：中性化后 AR 因子分组历史走势（20110901-20230401）



资料来源：Wind、招商证券

图 8: AR 因子多空净值走势 (20160401-20230401)





图 9: AR 因子组内多空收益率分布



资料来源: Wind、招商证券

资料来源: Wind、招商证券

但是,从组内多空的收益率分布和分组历史收益率的走势来看,AR 因子的多头拥挤程度在 9, 10 组表现的非常明显。在 1-8 组存在的分组收益率单调性在 9, 10 组消失。另一个明显的特点是空头端收益率显著高于多头端收益率。结合因子的多空走势图和因子 RankIC 表现,AR 因子的负 Alpha 属性比较明显。

由以上例子可以看出,常见基本面因子和量价因子多头都出现了不同程度的拥挤。量价因子的另一个问题是负 Alpha 属性显著,正 Alpha 则相对较弱。另一方面因子组合和组合优化的方法也较为类似,随着股票量化多头类策略资金的规模扩大,常见因子的多头收益可以预见将进一步降低。为了解决当前遇到的诸多问题:

- 1) 资产定价模型的线性结构假设并不准确
- 2) 常见基本面和量价因子的多头日趋拥挤
- 3) 量价类因子的负 Alpha 属性显著,正 Alpha 属性较弱
- 4) 因子合成以及组合优化方法类似,策略趋同

业界早已开始尝试在因子中加入非线性。例如 Barra 模型中中市值风格因子的构建。但因子与因子之间的非线性交互作用,仅仅通过先验通过在线性因子模型中加入非线性因子可能无法很好的解决。

随着机器学习技术的发展,深度神经网络已经运用到图像识别、自然语言处理等多个领域并完全战胜了传统的统计学习模型,例如树模型、SVM、隐马尔科夫模型等。因此,本文将尝试使用深度网络改进现有的 Alpha 模型,在因子构建、因子组合、收益预测等环节引入非线性,和自适应的权重训练的机制,以求改进当前传统 Alpha 模型遇到的诸多问题。

二、引入非线性的 Alpha 模型

因子模型的非线性存在已经广为人知,非线性存在于因子层面,同样存在于因子之间的交互作用,因此在建模非线性 Alpha 模型的时候,我们需要考虑的有:

- 1) 如何学习原始因子的非线性表示
- 2) 如何获得收益率预测性能最好的因子
- 3) 如何降低所学习到的因子之间的线性和非线性交互作用


在讨论这些问题之间,首先我们按照构建传统线性 Alpha 模型的思路构建一个具有大类因子合成。大类因子组合的线性网络。本文使用的因子库包括约 100 个因子,因子大类包括量价类、估值、盈利质量、风格等。具体说明见附录。其他固定设置如下:

表 1: 模型固定参数说明

名称	参数说明
股票池	全 A 股票，剔除上市不满三个月、ST、*ST、停牌的股票
数据集	基本面因子+量价因子
预测 Label	T+1 日至 T+21 日复权 VWAP 价格收益率
调仓周期	20 个交易日
因子预处理	3 倍 MAD 截断，zscore 标准化，缺失值填充为 0
中性化处理	市值、行业中性
跟踪基准	中证 500、中证 800、中证 1000
Batch 定义	一个交易截面上所有的股票为一个 Batch
数据划分	20110901-20230401，滚动训练模式；在训练集中划分最后 252 个交易日作为验证集；测试集为最近半年的所有交易日

资料来源：招商证券

图 10: 数据集划分说明



资料来源：招商证券

2.1. 线性基准网络

首线性网络与传统的 Alpha 框架保持了基本一致。包括原始因子的组合、大类因子合成以及收益率预测部分。

网络结构中，A1 层为线性表示层，输入为 $\mathbf{z}_m \in R^{N \times P}$ ，其中 N 为股票个数， P 为原始因子个数，经过第一层线性层后，输出为 64 维，第一层网络用来学习原始因子的线性表示，A2 层输入为 64 维输出为 6 维，第二层网络用来对学习到的因子进行线性加权，最后经过 BN 层后输出合成因子的 zscore。损失函数为 MSE 损失函数。使用 L2 正则化。

从传统因子模型的角度来看，第一层可以看作是原始因子合成大类因子，第二层可以看作大类因子合成收益预测 zscore:


$$\mathbf{h}_1 = \mathbf{z}_m \mathbf{w}_1 + \mathbf{b}_1$$

$$\mathbf{h}_2 = \mathbf{h}_1 \mathbf{w}_2 + \mathbf{b}_2$$

$$\mathbf{o} = \text{zscore}(\mathbf{h}_2)$$

与传统因子模型不同的地方在于：传统因子模型通常分两步完成大类因子合成以及收益率预测，在线性 Alpha 网络中权重由优化算法训练得到，使用 L2 正则减少因子权重缓解过拟合。


图 11: 线性 Alpha 网络结构



资料来源：招商证券


按照上述的网络结构和训练流程可以得到合成的 zscore 因子，表现如下：

图 12: 线性 Alpha 模型 RankIC 走势图



资料来源：招商证券

图 13: 分组年化基准对冲收益 (20160401-20230401)




资料来源：招商证券

线性网络在过去 7 年间，平均 RankIC 为 10.12%，ICIR（未年化）为 1.13。从 IC 的角度来看，线性网络表现不俗。但是从年化基准对冲的年化收益率来看，多头年化收益率为 11.34%，空头年化收益率为 -28.4%，IC 的贡献主要来自于空头端。

多头等权策略组合表现如图所示：

图 14: 线性 Alpha 模型多头等权策略历史表现



资料来源: Wind、招商证券

2.2.非线性 Alpha 网络

在网络中引入非线性，利用神经网络来提高因子模型的表示能力。这里使用 MLP（多层感知机）来构建，与线性网络的架构类似。同样分为因子表示学习层，大类因子层以及输出层。

表 2: MLP 网络参数设置

名称	参数说明
输入维度	截面股票个数*特征维度
输出维度	截面股票个数*1
隐藏层神经元个数	64
初始学习率	0.0005
优化算法	Adam
权重衰减	无
损失函数	MSE 损失函数作为基准
早停设置	验证集 loss, 5 个 epoch 不再下降, max_epoch 设置为 1000

资料来源: 招商证券

MLP 的主要结构包括输入层，隐藏层以及输出层。其中重要的结构参数是隐藏层的层数与隐藏层神经元个数。研究表明：


- 1) 当隐藏层为 0 时，神经网络只能表示线性可分的函数
- 2) 当隐藏层为 2 时，可以拟合任何一个有限空间到另一个有限空间的连续映射
- 3) 当隐藏层大于 3 时，额外的隐藏层可以学习复杂的特征描述（类似自动特征工程）

本文中网络结构中隐藏层数为 3 层。隐藏层神经元个数的经验法则：

$$N_h = \frac{N_s}{(\alpha * (N_i + N_o))}$$


其中 N_i 为输入层神经元的个数； N_o 为输出层神经元个数； N_s 为训练集样本数目； α 为经验变量，取值范围为 2-10。本文中 MLP 隐藏层神经元个数取 64。

图 15: 非线性 Alpha 网络结构



资料来源：招商证券

图 16: ReLU vs Sigmoid 激活函数




资料来源：招商证券

神经网络中常用的激活函数有 Sigmoid、Tanh、ReLU、LeakyReLU。ReLU 激活函数最为常用。ReLU 激活函数在正值区间梯度恒定，可以加快梯度下降的速度。从而加快训练速度。但是 ReLU 激活函数也存在一定的缺陷。

在因子模型训练的场景下，一般原始因子在预处理过程中都会进行标准化使其分布为近似正态分布。在图中的网络结构中，输入的全连接层直接接了一个 BN 层同样使得分布在零附近。那么在初始输入层以及浅层隐藏层使用 ReLU 激活函数会导致死神经元的现象。即一定比例的神经元输出恒定为随机初始化的 Bias。


因此在本文中 MLP 网络结构中，前两层激活函数为 Sigmoid，最后一层激活函数为 ReLU。

图 17: 非线性 Alpha 模型 RankIC 走势图 (MLP)



资料来源：招商证券

图 18: 分组年化基准对冲收益 (20160401-20230401, MLP)



资料来源：招商证券

从结果来看，基于 MLP 构建的非线性 Alpha 模型，在过去 7 年平均 RankIC 为 9.27%，ICIR（未年化）为 1.24，相比于线性网络，平均 RankIC 略有下降，ICIR 有一定的提高，多空夏普以及多空最大回撤显著改善，说明合成因子的稳定性显著提高。另一方面从基准对冲的年化收益来看，多头年化收益率提高约 1.9%。分组收益率的

单调性有所提升。


表 3: MLP 模型与基准线性模型合成因子表现对比

	RankIC 均值	ICIR	IC 胜率	IC 的 t 值	多空收益率	多空夏普	多空最大回撤	多头月均换手率
基准线性模型	10.43%	4.09	87.29%	47.52	52.90%	3.97	-15.14%	70.20%
MLP 模型	9.27%	4.40	87.94%	51.29	56.34%	4.92	-7.76%	72.60%

资料来源: 招商证券

MLP 多头等权策略历史表现如下:

图 19: 非线性 Alpha 模型多头等权策略历史表现 (MLP+MSE 损失)



资料来源: Wind、招商证券

MLP 多头等权策略与基准线性模型对比结果如下:

表 4: MLP 与基准线性模型多头等权策略表现对比

年份	组合	年化收益率	年化波动率	夏普率
2016	线性模型	32.88%	18.50%	1.64
	MLP	37.34%	19.43%	1.74
2017	线性模型	-6.14%	14.09%	-0.38
	MLP	-11.41%	15.37%	-0.71
2018	线性模型	6.52%	18.97%	0.43
	MLP	10.27%	20.01%	0.59
2019	线性模型	17.28%	15.89%	1.08
	MLP	17.20%	16.64%	1.04
2020	线性模型	7.26%	18.44%	0.47
	MLP	8.64%	18.58%	0.54
2021	线性模型	17.88%	14.37%	1.22
	MLP	25.71%	14.91%	1.61
2022	线性模型	2.91%	18.06%	0.25
	MLP	9.00%	18.82%	0.55

资料来源: 招商证券

2.3. 因子正交化正则

在传统因子模型中，在合成大类因子的过程中，通常会判断细分因子之间相关性，并根据 IC 值和相关性剔除相关性较高的因子。或者对现有的因子进行线性回归取残差作为新的因子。

$$\beta_{2,t} = a_t * \beta_{1,t} + b_t + \epsilon_t$$

通过共线性分析、取残差等手段提升大类因子的 IC 表现。对大类因子进行 zscore 合成的时候，解释变量之间的相关性会影响权重的稳定性，进而降低模型的性能。另一方面，在给了解释变量个数的前提下，解释变量之间的相关性越低，模型性能越好。

$$\hat{\theta} = (X^T X)^{-1} X^T Y$$

在广义线性回归中， $X^T X$ 可以看作样本的协方差矩阵（假设样本已经去均值），当样本特征之间具有较高的相关性时， $X^T X$ 不能列满秩。且标准误 $se\hat{\theta}$ 增大。

在传统线性模型中，我们一般通过 LASSO 回归、岭回归等方法来减少变量的共线性。在 MLP 因子网络中，从原始因子合成大类因子的过程，我们更希望得到相关性更低的大类因子。因此，可以考虑通过增加正则项的方式来降低最终学习到的大类因子的相关性。

对因子相关性的惩罚可以通过惩罚 $X^T X$ 的范数来实现，通常可以直接惩罚 $X^T X$ 的 Frobenius 范数：


$$L(\theta) = \|X^T X\|_F$$

但这样做存在一个问题，由于 $X^T X$ 的对角元素为因子的方差，直接惩罚设置 $X^T X$ 的 F 范数会共同惩罚每个因子的方差和因子之间的协方差，因此，这里优化目标为 $X^T X$ 的非对角元素为 0，即只惩罚因子之间的协方差：

$$L(\theta) = \|X^T X - \text{diag}(X^T X)\|_F$$


最终的目标函数为： $LOSS = MSE + \lambda * L(\theta)$ ， λ 为惩罚系数。

图 20：加入正交惩罚的 MLP 因子网络



资料来源：招商证券


图 21：正则化 MLP 的 zscore 分组对冲基准年化收益



资料来源：招商证券

按照上述训练步骤可以得到合成 zscore 的表现如下：

图 22：非线性 Alpha 模型 RankIC 走势图（MLP+正交惩罚+MSE 损失）



资料来源：招商证券

表 5：加入正交惩罚项后合成 zscore 的表现对比

	RankIC 均值	年化 ICIR	IC 胜率	IC 的 t 值	多空年化收益率	多空夏普	多空最大回撤	多头月均换手率
MLP 模型	9.27%	4.40	87.94%	51.29	56.34%	4.92	-7.76%	72.60%
MLP+正交惩罚	10.07%	4.33	88.60%	50.3	62.39%	4.95	-9.50%	68.50%

资料来源：招商证券

加入正交惩罚后，合成 zscore 的 RankIC 表现小幅提升。但多头对冲基准的年化收益率从 13.25% 提高到 15.91%，多头收益率对 RankIC 的贡献提升。

2.4. 优化目标的改进

损失函数是神经网络的重要设计，在因子模型的场景下，常用的损失函数如下：

1) MSE 损失函数：

$$MSE = \|\mathbf{y} - \mathbf{y}_l\|_2$$

2) Pearson 相关系数，IC（可以看作是余弦相似度）：

$$IC(y, \hat{y}) = \frac{\sum_{i=1}^n (y_i - \bar{y})(\hat{y}_i - \bar{\hat{y}})}{\sqrt{\sum_{i=1}^n (y_i - \bar{y})^2} \sqrt{\sum_{i=1}^n (\hat{y}_i - \bar{\hat{y}})^2}}$$

3) 改进的 CCC 损失函数，用于改进 Pearson 相关系数的凸性：

$$CCC = \frac{2\sigma_{yy}}{MSE + 2\sigma_{yy}}$$

其中 σ_{yy} 为 Pearson 相关系数。在因子模型的场景下，我们通常希望模型的样本外 IC 能够尽可能高，直接的想法是使用 Pearson 相关系数作为损失函数。但 Pearson 相关系数非凸的特性可能会导致收敛困难，因此在实际过程中，参照线性回归中：


$$SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

$$SSE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

$$R^2 = \frac{SSR - SSE}{SST} = \rho_{yy}^2$$

可以知道在线性模型中，优化 MSE 损失与优化 IC 基本等价，因此通常使用 MSE 损失函数作为 IC 的近似目标，在深度网络模型训练收敛和参数估计受到样本和优化算法以及随机初始化的影响。两者可能有所区别。CCC 损失则是结合了 IC 和 MSE 损失函数。本文在实验中测试了三种不同的损失函数对模型结果的影响。

图 23: MLP 网络不同损失函数分组对冲基准年化收益率（正则化）



资料来源：招商证券

可以看出 IC 损失函数的多头收益表现最好，其次是 CCC 损失函数。CCC 损失函数的空头收益率显著低于前两者。但多头收益率表现超过 MSE 损失函数。从多空夏普和多空最大回撤的表现来看，CCC 损失函数的稳定性最好。


表 6: 不同模型合成 zscore 表现对比

	RankIC 均值	年化 ICIR	IC 胜率	IC 的 t 值	多空年化收益率	多空夏普	多空最大回撤	多头月均换手率
基准线性模型	10.43%	4.09	87.29%	47.52	52.90%	3.97	-15.14%	70.20%
MLP 模型	9.27%	4.40	87.94%	51.29	56.34%	4.92	-7.76%	72.60%

	RankIC 均值	年化 ICIR	IC 胜率	IC 的 t 值	多空年化收益率	多空夏普	多空最大回撤	多头月均换手率
MLP+正交+MSE	10.07%	4.33	88.60%	50.30	62.39%	4.95	-9.50%	68.50%
MLP+正交+IC	11.02%	4.57	89.90%	53.30	63.49%	4.48	-12.49%	68.60%
MLP+正交+CCC	9.11%	4.49	91.60%	52.20	51.38%	5.26	-6.60%	65.00%


资料来源：招商证券

图 24：不同模型的多空净值历史表现（20160401-20230401）



资料来源：Wind、招商证券

图 25：不同模型多头等权组合历史表现（20160401-20230401）



资料来源：Wind、招商证券


结合多头对冲基准的历史走势，可以看出传统 Alpha 模型中代表单因子表现的 RankIC 均值、多空年化收益率在多头选股的场景下存在表现错配的现象。例如 MLP 正交+CCC 损失的多空收益率表现远不如 MLP 正交+MSE 损失模型，但多头组合的表现却好于后者基于 CCC 损失函数模型的表现。

2.5.模型分析

相比于线性模型，神经网络的可解释性并不直观。但在实际投资策略的构建过程中，往往需要对因子对策略的


贡献进行归因。在非线形模型中，可以使用方差筛选、卡方检验、互信息等方法；在树模型中可以使用离根节点的远近来判断特征的相对重要性。但神经网络的特征重要性分析相对复杂。近年来，学术界也在不断探讨深度神经网络这类模型的可解释性。Shapley 方法是其中比较经典的方法，最早由 UCLA 的教授 Lloyd Shapley 提出，主要用于解决合作博弈论中的分配均衡问题。在机器学习模型的可解释性方法中，SHAP 使用了类似的算法来判断模型中输入特征对结果的贡献。SHAP 值衡量了特征对实际预测值与平均预测值之差的贡献。

图 26：特征重要性示意图（SHAP 归因）



资料来源：招商证券，20220930-20230331

图 27：特征对模型输出的平均影响（SHAP 归因）



资料来源：招商证券，20220930-20230331

在对模型最近半年的输出进行 SHAP 归因后，发现流动性大类的因子对预测值的贡献相对较高，包括年化交易量比率、过去一个月的换手率等；量价指标的贡献整体要比基本面指标的贡献高；在常见风格因子上有一定的暴露。从模型输出的 zscore 与常见风格因子的平均截面相关系数也可以看出过去一段时间，模型输出与流动性因子、残差波动率的线性相关性较高。其次是价值和动量因子。此外在其他风格因子上没有呈现出明显的相关性。

表 7：模型 zscore 与常见风格因子的平均截面相关性（20160401-20230401）


	流动性	杠杆	价值	反转	成长	动量	市值	beta	残差波动率
流动性	1	-0.15	-0.28	0.08	-0.04	0.16	-0.34	0.35	0.59
杠杆	-0.15	1	0.45	0.08	-0.05	-0.05	0.22	-0.17	-0.13
价值	-0.28	0.45	1	0.16	-0.1	-0.21	0.15	-0.17	-0.37
反转	0.08	0.08	0.16	1	-0.25	-0.1	-0.34	-0.09	0.01
成长	-0.04	-0.05	-0.1	-0.25	1	0.14	0.13	0.11	0.04
动量	0.16	-0.05	-0.21	-0.1	0.14	1	0.29	0	0.26
市值	-0.34	0.22	0.15	-0.34	0.13	0.29	1	-0.05	-0.1
beta	0.35	-0.17	-0.17	-0.09	0.11	0	-0.05	1	0.22
残差波动率	0.59	-0.13	-0.37	0.01	0.04	0.26	-0.1	0.22	1
zscore	-0.46	0.06	0.2	-0.03	0.01	-0.12	-0.02	-0.02	-0.43

资料来源：招商证券

2.5.在不同成分股中的选股效果

这里以 MLP+正交惩罚+CCC 损失函数作为示例，来检验模型在不同的成分股中的选股效果。股票池分别为中证 500、中证 1000。从对冲基准的年化收益率来看，中证 1000 的表现最好，多头为 14.18%与全 A 的表现较为接近。其次是中证 500，多头收益率为 9.02%，中证 800 成分股中表现显著下降为 4.93%。

图 28：模型在不同成分股中的对冲基准年化收益率（20160401-20230401）



资料来源：Wind、招商证券

表 8：模型在不同成分股中选股的表现

	RankIC 均值	年化 ICIR	IC 胜率	IC 的 t 值	多空年化收益率	多空夏普	多空最大回撤	多头月均换手率
中证 1000	10.27%	3.52	85.24%	40.90	54.95%	3.65	-28.21%	69.20%
中证 500	7.32%	2.39	73.12%	27.78	22.34%	1.69	-27.45%	66.40%
中证 800	6.27%	2.28	74.76%	26.48	26.81%	1.82	-21.38%	66.30%

资料来源：招商证券

三、总结

本文基于传统的线性因子模型，提出了动态训练的 MLP 模型。在传统线性模型中引入非线性。从与基准的对比来看，MLP 模型与 L2 正则的线性模型 RankIC 并无明显提升。但因因子多空收益率，多空夏普均有明显提升。从多头对冲基准的年化收益率来看。提升的主要贡献是多头收益率的提高。

借鉴传统因子模型细分因子到大类因子的合成过程，本文尝试在合成因子的神经网络层加入对因子相关性的惩罚。以提高合成 zscore 的稳定性。从结果来看，加入正则惩罚后，合成因子的平均 RankIC 略有提高，但多头对冲基准的年化收益率显著提高。

最后本文测试了使用不同的损失函数 MSE、IC、CCC 对模型结果的影响，其中 IC 损失函数模型的因子多空表现和多头年化收益率的表现最好。CCC 损失函数的平均 RankIC 在所有模型表现最差。但多头收益率只比 IC 损失函数略差。这一现象显著体现了 IC 这单一指标并不能在多头选股的场景下有正确的表现评估。需要结合因子的多空夏普、多空最大回撤等稳定性指标并结合多头组合的表现来判断因子的多头选股能力。从模型对比表现可以看出在传统线性模型中引入非线性后，模型的 IC 指标并无明显提升。但因因子多头组合以及因子的稳定性均有了明显提升。

模型的输入原始也同样重要，本文所用的因子集合，量价指标占比相对较高。量价因子的空头端表现普遍好于多头端。较高比例的量价因子显然会拖累模型的整体表现。

参考文献:

1. Gu, S., Kelly, B., & Xiu, D. (2021). Autoencoder asset pricing models. *Journal of Econometrics*, 222(1), 429-450.
2. LeCun, Yann, Yoshua Bengio, and Geoffrey Hinton. "Deep learning." *nature* 521.7553 (2015): 436-444.
3. Jason Brownlee, How to Configure the Number of Layers and Nodes in a Neural Network.
4. Kelly, Bryan, Seth Pruitt, and Yinan Su, 2019, Characteristics are covariances: A unified model of risk and return, *Journal of Financial Economics*, forthcoming.
5. Liao J J Z, Lewis J W. A note on concordance correlation coefficient[J]. *PDA journal of pharmaceutical science and technology*, 2000, 54(1): 23-26.

附录：本文所使用的部分因子说明

表 9：因子说明表

因子类别	说明	方向	因子计算方法
估值	bp_lf	正	市净率 PB_LF 的倒数, pe_ratio_lf
	ep_ttm	正	市盈率 PE_TTM 的倒数, ep_ratio_ttm
	sp_ttm	正	市销率 PS_TTM 的倒数, sp_ratio_ttm
	dividend_yield_ttm	正	最新四个季度的季报的股利之和/公司当前股票总市值, $dividend_per_share/close$
	enterprice_multiple	正	EBITDA/EV, 企业价值倍数的倒数, $EV=市值+总负债-总现金=市值+净负债$
	book_value_per_share_ttm	正	每股净资产 $ttm=归属母公司股东权益合计\ ttm/总股本$
市值	ebitda_ttm	正	EBITDA=EBIT(息税前利润)+折旧费用+摊销费用
	ln_cap	负	$\ln(总市值)$, 总市值 = 总股本* A 股末复权收盘价
	return_on_equity_ttm	正	净资产收益率 $ttm=归属母公司净利润\ ttm*2/(归属母公司股东权益合计\ ttm+上期报表披露归属母公司股东权益合计\ ttm)$
	return_on_asset_ttm	正	总资产报酬率 $ttm=息税前利润\ ttm/总资产\ ttm$
成长	return_on_asset_net_profit_ttm	正	总资产净利率 $ttm=净利润\ ttm/总资产\ ttm$
	return_on_equity_diluted_ttm	正	摊薄净资产收益率 $ttm=归属母公司净利润\ ttm/归属母公司股东权益合计\ ttm$
	inc_return_on_equity_ttm	正	净资产收益率(摊薄)同比增长率 $ttm=摊薄净资产收益率\ ttm/去年摊薄净资产收益率\ ttm-1$
	return_on_invested_capital_ttm	正	净利润 $ttm+财务费用\ ttm/(资产总计\ ttm-流动负债\ ttm+应付票据\ ttm+短期借款\ ttm+年内到期的非流动负债\ ttm)$
	adjusted_return_on_equity_diluted_ttm	正	摊薄净资产收益率_扣除 $ttm=扣除非经常性损益后归属母公司的净利润\ ttm/归属母公司的股东权益合计\ ttm$
	adjusted_return_on_equity_ttm	正	母公司净利润 $ttm*2/(归属母公司股东权益合计\ ttm+上期报表披露的归属母公司股东权益合计\ ttm)$
经营	ebit_ttm	正	EBIT=经营利润+投资收益+营业外收入-营业外支出+以前年度损益/=净利润+所得税+利息; 公司价值
	income_from_main_operation_ttm	正	主营业务利润 $ttm=营业收入\ ttm-营业成本\ ttm-营业税金及附加\ ttm$
	operating_total_revenue_per_share_ttm	正	每股营业总收入 $ttm=营业总收入\ ttm/总股本$
	operating_revenue_per_share_ttm	正	每股营业收入 $ttm=营业收入\ ttm/总股本$
	diluted_earnings_per_share_ttm	正	摊薄每股收益 $ttm=归属母公司净利润\ ttm/该报告期末普通股总股本$
	expense_to_revenue_ttm	负	经营成本率 $ttm=营业总成本\ ttm/营业总收入\ ttm$
	profit_from_operation_to_revenue_ttm	正	营业利润率 $ttm=营业利润\ ttm/营业总收入\ ttm$
	ebit_per_share_ttm	正	每股息税前利润 $ttm=息税前利润\ ttm/总股本$
	adjusted_fully_diluted_earnings_per_share_ttm	正	稀释每股收益_扣除 $ttm=扣除非经常损益的净利润\ ttm/稀释普通股\ ttm$
	adjusted_earnings_per_share_ttm	正	基本每股收益_扣除 $ttm=扣除非经常性损益的净利润\ ttm/普通股加权股本\ ttm$
现金流	operating_cash_flow_per_fcff_ttm	正	每股经营现金流 $ttm=经营活动产生的现金流量净额\ ttm/总股本$
	free_cash_flow_equity_per_share_ttm	正	企业自由现金流量 ttm
	free_cash_flow_company_per_share_ttm	正	每股企业自由现金流 $ttm=企业自由现金流量\ ttm/总股本$
	ocf_to_current_ratio_ttm	正	连续四季度经营活动产生的现金流量净额 $ttm/流动负债\ ttm$
	ocf_to_debt_ttm	正	经营活动产生的现金流量净额 $ttm/负债合计\ ttm$
	undistributed_profit_per_share_ttm	正	每股未分配利润 $ttm=企业当期未分配利润总额\ ttm/总股本$
	cash_flow_ratio_ttm	正	现金流量比率 $ttm=未扣除利息所得税折旧和摊销前的盈余\ ttm/年利息支出\ ttm$
	tangible_asset_per_share_lf	正	每股有形资产 $lf=(资产总计\ mrq-无形资产\ mrq-商誉\ mrq)/总股本$
财务	earned_reserve_per_share_lf	正	每股盈余公积金 $lf=盈余公积金\ mrq/总股本$
	cash_equivalent_per_share_lf	正	每股货币资金余额 $lf=货币资金余额\ mrq/总股本$
	invested_capital_lf	正	全部投入资本 $lf=归属于母公司所有者权益合计\ mrq+带息债务\ lf$

	non_interest_bearing_current_debt_if	正	应付账款 mrq+预收账款 mrq+应付职工薪酬 mrq+应交税费 mrq+其他应付款 mrq+预提费用 mrq+递延收益 mrq+其他流动负债 mrq
	retained_earnings_if	正	留存收益 If=盈余公积金 mrq+未分配利润 mrq
	retained_earnings_per_share_ttm	正	每股留存收益 ttm=留存收益 ttm/总股本
	one_month_share_turnover	负	1 个月换手率
流动性	three_months_share_turnover	负	3 个月换手率
	twelve_months_share_turnover	负	12 个月换手率
	annualized_trade_value_ratio	负	年化交易量比率
	historical_sigma	负	在计算 BETA 所进行的时间序列回归中，取回归残差收益率的波动率
风格	daily_standard_deviation	负	日收益率在过去 252 个交易日的波动率，半衰期 42 个交易日
	historical_alpha	负	股票收益率对沪深 300 收益率进行时间序列回归，回归时间窗口为 252 个交易日，半衰期 63 个交易日
	relative_strength	负	(1) 计算非滞后的相对强度：对股票的对数收益率进行半衰指数加权求和，时间窗口 252 个交易日，半衰期 126 个交易日 (2) 以 11 个交易日为时间窗口，滞后 11 个交易日，取非滞后相对强度的等权平均值
	variation_in_earnings	负	盈利波动率
技术	CYF	负	$CYF=100-100/(1+EMA(HSL,N))$ ，HSL 为换手率
	AR	负	人气意愿指标， $AR=SUM(HIGH-OPEN,M1)/SUM(OPEN-LOW,M1)*100$ ，M1=26
	TAPI	负	加权指数成交值， $API=AMOUNT/CLOSE$ ，AMOUNT 代表成交额
	BIAS20	负	乖离率， $(CLOSE-MA(CLOSE,L1))/MA(CLOSE,L1)*100$ ，L1=20
	ROC	负	变形率指标， $ROC=100*(CLOSE-REF(CLOSE,N))/REF(CLOSE,N)$
	DPO	负	区间震荡线， $DPO=CLOSE-REF(MA(CLOSE,M1),M2)$ ，M1=20，M2=10
	MTM	负	动量线， $MTM=CLOSE-REF(CLOSE,N)$ ，N=14
	CR	负	$CR=SUM(MAX(O,HIGH-MID),N)/SUM(MAX(O,MID-LOW),N)*100$ ； $MID=REF(HIGH+LOW,1)/2$
	TRIX	负	三重指数移动平均， $TRIX=(TR-REF(TR,1))/REF(TR,1)*100$ ； $TR=EMA(EMA(EMA(CLOSE,M1),M1),M1)$
	MACD_DIFF	负	$MACD_DIFF=EMA(CLOSE,SHORT)-EMA(CLOSE,LONG)$ ，SHORT=12，LONG=26
	VOLT20	正	20 日收盘价的标准差

资料来源：招商证券

分析师承诺

负责本研究报告的每一位证券分析师，在此申明，本报告清晰、准确地反映了分析师本人的研究观点。本人薪酬的任何部分过去不曾与、现在不与、未来也不会与本报告中的具体推荐或观点直接或间接相关。

评级说明

报告中所涉及的投资评级采用相对评级体系，基于报告发布日后 6-12 个月内公司股价（或行业指数）相对同期当地市场基准指数的市场表现预期。其中，A 股市场以沪深 300 指数为基准；香港市场以恒生指数为基准；美国市场以标普 500 指数为基准。具体标准如下：

股票评级

强烈推荐：预期公司股价涨幅超越基准指数 20%以上

增持：预期公司股价涨幅超越基准指数 5-20%之间

中性：预期公司股价变动幅度相对基准指数介于±5%之间

减持：预期公司股价表现弱于基准指数 5%以上

行业评级

推荐：行业基本面向好，预期行业指数超越基准指数

中性：行业基本面稳定，预期行业指数跟随基准指数

回避：行业基本面转弱，预期行业指数弱于基准指数

重要声明

本报告由招商证券股份有限公司（以下简称“本公司”）编制。本公司具有中国证监会许可的证券投资咨询业务资格。本报告基于合法取得的信息，但本公司对这些信息的准确性和完整性不作任何保证。本报告所包含的分析基于各种假设，不同假设可能导致分析结果出现重大不同。报告中的内容和意见仅供参考，并不构成对所述证券买卖的出价，在任何情况下，本报告中的信息或所表述的意见并不构成对任何人的投资建议。除法律或规则规定必须承担的责任外，本公司及其雇员不对使用本报告及其内容所引发的任何直接或间接损失负任何责任。本公司或关联机构可能会持有报告中所提到的公司所发行的证券头寸并进行交易，还可能为这些公司提供或争取提供投资银行业务服务。客户应当考虑到本公司可能存在可能影响本报告客观性的利益冲突。

本报告版权归本公司所有。本公司保留所有权利。未经本公司事先书面许可，任何机构和个人均不得以任何形式翻版、复制、引用或转载，否则，本公司将保留随时追究其法律责任的权利。