

随机森林与传统多因子模型的选股风格对比

——多因子模型研究系列之四

分析师：宋旻

SAC NO: S1150517100002

2018 年 7 月 26 日

证券分析师

宋旻

022-28451131

18222076300

songyang@bhq.com

相关研究报告

《多因子模型研究之一：单因子测试》20171011

《多因子模型研究之二：收益预测模型》20171229

《多因子模型研究之三：风险模型与组合优化》20180416

《使用随机森林算法的行业轮动模型——行业轮动专题一》20180708

核心观点：

● 模型建立方法：

本篇报告中，我们分别使用机器学习中的随机森林算法与传统的线性回归方法，针对沪深 300 成分股、中证 500 成分股与全体 A 股构建多因子选股模型，比较二者的历史表现。同时针对两类模型选出的股票池，运用业绩归因方法来探寻两个模型在选股上的风格异同，通过对比组合的因子暴露和因子收益来确定两种选股结果的主要收益来源。

随机森林多因子模型构建方法：每个月月末截面期，选取下个月收益排名前 30% 的股票作为正例，后 30% 的股票作为负例。将当前月份前 12 个月的样本合并形成训练集。使用训练集训练随机森林模型，预测下一月个股涨跌概率，选取上涨概率最高的 50 支股票组成股票池。

传统多因子模型构建方法：采用估值、盈利、成长、动量、反转、波动率、流动性、市值八大类因子建立线性回归模型，采用 12 个月的移动平均方法预测因子未来收益。

● 回测结果总结：

在各个样本池中，随机森林模型的表现相比于传统多因子模型均有一定程度的提升，尤其是在相比业绩基准的月度胜率上的提升十分显著。这说明随机森林模型相比传统多因子模型具有更强的灵活性，可以更快的把握市场风格的转变。

在业绩归因模型中，传统多因子模型在大部分因子暴露上的波动率均明显大于随机森林模型。这说明在不加限制的情况下，传统多因子模型的选股风格可能会更加极端化。

通过对于不同样本范围内选股结果的分析，可以发现，股票池中的小市值股票越多（全 A>中证 500>沪深 300），模型选股结果的因子波动性越大，同时在市值因子的暴露也逐步上升。对市值因子的依赖是多因子模型一直面临的问题，在实际应用中，我们推荐对于市值因子做一定的风险敞口控制，以防止因子失效带来的大幅回撤风险。

● 风险提示：

随着市场环境变化，模型存在失效风险。

目 录

1. 概述.....	5
2. 随机森林多因子模型的建立与运行结果	5
2.1 因子提取.....	5
2.2 数据前期处理.....	9
2.3 模型建立.....	10
3. 回测结果.....	11
3.1 针对沪深 300 的选股模型	11
3.2 针对中证 500 股票的选股模型	14
3.3 针对全体 A 股的选股模型	18
4. 总结与未来研究方向展望	21

表目录

表 1: 因子定义.....	6
表 2: 沪深 300 选股模型历史回测结果	11
表 3: 沪深 300 选股模型历史分年度收益统计结果	11
表 4: 沪深 300 选股模型因子统计结果	13
表 5: 中证 500 选股模型历史回测结果	15
表 6: 中证 500 选股模型历史分年度收益统计结果	15
表 7: 中证 500 选股模型因子统计结果	16
表 8: 全体 A 股选股模型历史回测结果	18
表 9: 全体 A 股选股模型历史分年度收益统计结果	18
表 10: 全体 A 股选股模型因子统计结果	20

图目录

图 1: 随机森林算法示意图	5
图 2: 沪深 300 选股模型回测收益曲线	12
图 3: 沪深 300 选股模型对冲基准回测收益曲线	12
图 4: 沪深 300 选股模型市值因子历史暴露	13
图 5: 沪深 300 选股模型成长因子历史暴露	13
图 6: 沪深 300 选股模型盈利因子历史暴露	13
图 7: 沪深 300 选股模型估值因子历史暴露	13
图 8: 沪深 300 选股模型动量因子历史暴露	14
图 9: 沪深 300 选股模型反转因子历史暴露	14
图 10: 沪深 300 选股模型波动率因子历史暴露	14
图 11: 沪深 300 选股模型流动性因子历史暴露	14
图 12: 中证 500 选股模型回测收益曲线	15
图 13: 中证 500 选股模型对冲基准回测收益曲线	16
图 14: 中证 500 选股模型市值因子历史暴露	17
图 15: 中证 500 选股模型成长因子历史暴露	17
图 16: 中证 500 选股模型盈利因子历史暴露	17
图 17: 中证 500 选股模型估值因子历史暴露	17
图 18: 中证 500 选股模型动量因子历史暴露	17
图 19: 中证 500 选股模型反转因子历史暴露	17
图 20: 中证 500 选股模型波动率因子历史暴露	18
图 21: 中证 500 选股模型流动性因子历史暴露	18
图 22: 全体 A 股选股模型回测收益曲线	19
图 23: 全体 A 股选股模型对冲基准回测收益曲线	19
图 24: 全体 A 股选股模型市值因子历史暴露	20
图 25: 全体 A 股选股模型成长因子历史暴露	20
图 26: 全体 A 股选股模型盈利因子历史暴露	20
图 27: 全体 A 股选股模型估值因子历史暴露	20
图 28: 全体 A 股选股模型动量因子历史暴露	21
图 29: 全体 A 股选股模型反转因子历史暴露	21
图 30: 全体 A 股选股模型波动率因子历史暴露	21
图 31: 全体 A 股选股模型流动性因子历史暴露	21

1. 概述

长久以来，多因子模型都是在量化选股中最常用的模型之一，该模型通过探寻因子和股票收益率之间的统计关系，预测股票未来的收益，从中选择优质标的。传统的多因子模型假设标的未来收益与因子间存在线性关系，通过截面线性回归构建模型。历史上，该模型在中国 A 股市场中取得了较好的效果。2017 年以来，A 股市场风格经历了较大转变，传统多因子模型的表现较之前有了一定的回撤。于是寻找更及时、更高效的收益预测算法成了多因子模型研究中亟需解决的问题。

随机森林算法是机器学习算法的一种。相比于其他机器学习算法和传统线性回归模型，随机森林算法具有直观，参数少，抗干扰，不易出现过拟合等优点。在之前的报告中，我们使用随机森林算法建立的针对行业指数的择时模型，取得了较好的择时结果。在本篇报告中，我们将随机森林算法引入多因子模型，使模型更灵活更稳定，回测取得了较好的结果。关于随机森林算法的介绍，请参见报告《使用随机森林算法的行业轮动模型——行业轮动专题一》

图 1：随机森林算法示意图



资料来源：Wind，渤海证券研究所

2. 随机森林多因子模型的建立与运行结果

2.1 因子提取

随机森林模型与传统线性回归模型不同，因子不需要规避多重共线性限制，可以尽量多的考虑各种有效因子。因子的选择上，我们具体测试了估值、盈利、成长、动量、波动率、流动性、市值、反转八大类共 91 个小因子，并在测试名单中涵

盖了 Barra CNE5 手册中的大部分因子，具体因子定义见下表：

表 1：因子定义

大类因子	小类因子	因子解释
反转	RSTR_barra	Barra 因子； $\sum_{t=L}^{T+L} w_t [\ln(1+r_t)]$ ， $L=21$ ， $T=500$ ，半衰期 120 日
	RSTR_m24	$\sum_{t=L}^{T+L} w_t [\ln(1+r_t)]$ ， $L=1$ ， $T=240$ ，半衰期 120 日
	RSTR_m12	$\sum_{t=L}^{T+L} w_t [\ln(1+r_t)]$ ， $L=1$ ， $T=240$ ，半衰期 60 日
	RSTR_m6	$\sum_{t=L}^{T+L} w_t [\ln(1+r_t)]$ ， $L=1$ ， $T=120$ ，半衰期 30 日
	RSTR_m3	$\sum_{t=L}^{T+L} w_t [\ln(1+r_t)]$ ， $L=1$ ， $T=60$ ，半衰期 15 日
	RSTR_m1	$\sum_{t=L}^{T+L} w_t [\ln(1+r_t)]$ ， $L=1$ ， $T=20$ ，半衰期 5 日
	RS_1	最新收盘价/21 个交易日前收盘价
动量	RS_3	最新收盘价/63 个交易日前收盘价
	RS_6	最新收盘价/126 个交易日前收盘价
	RS_12	最新收盘价/252 个交易日前收盘价
	Alpha	alpha 系数；个股收益率序列与沪深 300 指数收益率序列以半衰期指数加权，得到 alpha 系数，半衰期为 60 日
	Size	总市值
市值	non-linear-size	Barra 因子；中等市值；将总市值的对数与总市值立方的对数回归得到残差，再对残差做标准化处理
	marketcap	流通市值
	STOM	月度平均换手率；最近一个月的交易量/流通股数
	STOQ	季度平均换手率；最近一季度的交易量/流通股数
	STOS	半年平均换手率；最近半年的交易量/流通股数
	STOA	年度平均换手率；最近一年的交易量/流通股数
	STOM_barra	Barra 因子；公式： $\ln\left(\sum_{t=1}^{21} \frac{V_t}{S_t}\right)$ ， V_t 为 t 日成交金额， S_t 为 t 日流动市值
	STOQ_barra	Barra 因子；公式： $\ln\left[\frac{1}{T} \sum_{t=1}^T \exp(STOM_t)\right]$ ， $T=63$ 个交易日
	STOA_barra	Barra 因子；公式： $\ln\left[\frac{1}{T} \sum_{t=1}^T \exp(STOM_t)\right]$ ， $T=244$ 个交易日
流动性	Ins	机构持股比例；机构持股变动/总股本
	ins_c	机构持股比例变动
	MSM	一个月换手率变动；最近 1 个月换手率/最近 1 年换手率
	MSQ	季度换手率变动；最近 3 个月换收益率/最近 1 年换手率
	MSS	半年换手率变动；最近 6 个月换收益率/最近 1 年换手率
	DASTD	Barra 因子；年度平均波动率；累计日波动率以半衰期指数加权，半衰期为 40 日
	CMRA	Barra 因子；年度收益率波动
波动率	HSIGMA	Barra 因子；sigma：个股收益率序列与沪深 300 指数收益率序列以半衰期指数加权，得到残差，对残差求标准差得到 sigma，半衰期为 60 日

成长	Beta	Barra 因子；贝塔系数；个股收益率序列与沪深 300 指数收益率序列以半衰期指数加权，得到 beta 系数，半衰期为 60 日
	yieldvol_1	月度日收益率波动率；一个月日收益率标准差
	yieldvol_3	季度日收益率波动率；三个月日收益率标准差
	yieldvol_6	半年日收益率波动率；半年日收益率标准差
	high_low_1	月度股价波动；最高价 / 最低价（最近一个月内价格）
	high_low_3	季度股价波动；最高价 / 最低价（近三个月内价格）
	high_low_6	半年股价波动；最高价 / 最低价（近六个月内价格）
	high_low_12	全年股价波动；最高价 / 最低价（近十二个月内价格）
	VOL_1	成交量月度波动率；1 月波动率标准差
	VOL_3	成交量季度波动率；3 月波动率标准差
	VOL_6	成交量半年波动率；6 月波动率标准差
	VOL_12	成交量年度波动率；12 月波动率标准差
	growth_ttm_or	营业收入 ttm 一年增长率
	growth_ttm_profit	净利润 ttm 一年增长率
	qfa_yoy sales_qq	单季度营业收入一年增长率
	qfa_yoy netprofit_qq	单季度归母净利润一年增长率
	qfa_yoy ocf_qq	单季度经营性现金流一年增长率
	qfa_yoy profit_qq	单季度净利润一年增长率
	qfa_roe_qq	单季度 roe 一年增长率
	yoy_profit_qq	净利润一年增长率
	yoy_growth_netprofit_qq	归母净利润一年增长率
	yoy_or_qq	营业收入一年增长率
	yoyroe_qq	roe 一年增长率
	yoyocf_qq	经营性现金流一年增长率
	growth_roe_qq_3	roe 三年增长率
	growth_netprofit_qq_3	归母净利润三年增长率
	growth_or_qq_3	营业收入三年增长率
	growth_profit_qq_3	净利润三年增长率
	growth_ocf_qq_3	经营性现金流三年增长率
	growth_profit_qq_5	净利润五年增长率
	growth_ocf_qq_5	经营性现金流五年增长率

盈利	growth_roe_qq_5	roe 五年增长率
	SGRO	Barra 因子; 过去 5 年企业营业收入复合增长率
	EGRO_5	Barra 因子; 过去 5 年企业归属母公司净利润复合增长率
	EGIB	Barra 因子; 未来 3 年企业一致预期净利润增长率
	EGIB_S	Barra 因子; 未来 1 年企业一致预期净利润增长率
	CETOP	Barra 因子: 个股现金收益比股票价格
	roe_q	当季净资产收益率
	roe_ttm	滚动 ROE
	roa_q	当季资产收益率、资产回报率
	roa_ttm	滚动 ROA
	qfa_grossprofitmargin	当季毛利率
	grossprofitmargin_ttm	滚动毛利率
	profitmargin_q	当季扣非后利润率
	profitmargin_ttm	滚动扣非后利润率
	assetturn_q	当季资产周转率
	assetturn_ttm	滚动资产周转率
	operationcashflowratio_q	当季经营活动现金净流比率
	operationcashflowratio_ttm	滚动经营活动现金净流比率
	ROIC	投入资本回报率
	EBIT2EV	投资收益率; 息税前利润/投入资本
	CASHROIC	现金 ROIC
	FreeCashflowYield	自由现金流比率; 经营性活动产生的净现金流-构建其他长期资产支付的现金/总市值
	sales2EV	营业收益率; 营业收入_TTM/总市值+非流动负债
	cashflow1	经营活动净现金流/总市值
	cashflow2	经营活动净现金流/营业收入
	cashflow3	经营活动净现金流/营业收入净收益
	invturn_qq	存货周转率; 存货成本/平均存货余额
	arturn_qq	应收账款周转率; 当期销售净收入/平均应收账款
	fatur_n_qq	固定资产周转率; 销售收入/平均固定资产
	assetturnover_ttm	滚动总资产周转率; 营业收入 ttm / [(期初资产总额+期末资产总额) / 2]
	assetturn_qq	总资产周转率; 营业总收入 / [(期初资产总额+期末资产总额) / 2]
	longdebtworkingcapital_qq	长期债务与营运资金比率; 长期债务/营运资本
	finaexpensetogr_qq	财务费用比率; 财务费用/主营业务收入
	gctogr_qq	营业费用比率; 营业费用/主营业务收入
价值	ETOP	Barra 因子; 历史 EP 值; 利用过去 12 个月个股净利润除以当前市值。
	BTOP	Barra 因子; 历史 BP 值; 普通股权益价值/市值
	epcut	市盈率 (扣除非经营性损益部分, 即公司经营性盈利与市值之比值)

bp_lf	最近公告日 BP
ncfp	净现金市值比；净现金流 /总市值
ocfp	营业现金流比率；经营性现金流 /总市值
dividendyield	股息率；过去一年分红/总市值
stop1	营收市值比，市销率 PS（TTM）倒数
stop2	营收市值比，市销率 PS（LYR）倒数
ep_rel	相对 PE；PE/行业 PE
bp_rel	相对 PB；PB/行业 PB
PEG	市盈率相对盈利增长比率
EPIBS	Barra 因子；预期 EP 值

资料来源：渤海证券研究所、The Barra China Equity Model (CNE5)

2.2 数据前期处理

提取的因子数据需经过数据对齐、去极值、标准化、缺失值处理等步骤，才可进入下一步的选股模型。

数据对齐：上市公司财报的报告期和报告发布日期之间有一定延迟，为避免未来信息，在提取数据的时候，需要对日期进行修正，保证因子数据为当时能获取的最新财报数据。

去极值：为避免数据中的极端值对回归结果产生过多影响，我们使用“中位数去极值法”，将超过上下限的极端值用上下限值代替。

$$\tilde{x}_i = \begin{cases} x_M + 5 \times x_{MAD}, & x_i > x_M + 5 \times x_{MAD} \\ x_i, & x_M - 5 \times x_{MAD} \leq x_i \leq x_M + 5 \times x_{MAD} \\ x_M - 5 \times x_{MAD}, & x_i < x_M - 5 \times x_{MAD} \end{cases}$$

x_i : 原始序列

x_M : 序列 x_i 的中位数

x_{MAD} : 序列 $|x_i - x_M|$ 的中位数

$\tilde{x}_i$: 去极值处理后的新序列

缺失值处理：提取出的因子可能会因为技术原因等情况出现缺失值，将缺失值设

为申万一级行业个股当期因子的中位数。

标准化: 由于各个因子的单位不同, 为了使其具有可比性, 需要对其进行 ZScore 标准化处理, 即减去序列均值除以序列标准差, 使因子序列近似成为一个符合 $N(0,1)$ 正态分布的序列。

行业市值中性化: 将最后得到的因子序列对流动市值与行业哑变量做线性回归, 取残差作为新的因子值。

2.3 模型建立

样本范围: 本篇报告中, 我们针对三类样本做了回测, 分别为沪深 300 成分股、中证 500 成分股以及全体 A 股。回测标的中剔除 ST/PT 股票, 剔除上市交易不满两年的股票。

样本期: 2010 年 1 月-2018 年 6 月, 按月提取。

训练集成: 每个月月末截面期, 选取下个月收益排名前 30% 的股票作为正例 ($y=1$), 后 30% 的股票作为负例 ($y=0$)。将当前月份前 12 个月的样本合并形成训练集。使用训练集训练随机森林模型, 预测下一月个股涨跌概率。

模型建立方法: 每月选取 N 只股票组成股票池 ($N=50$), 等权配置。回测中已剔除停牌、涨停等不能交易的因素。

对比传统多因子模型: 为了更好的展示随机森林多因子模型的选股效果, 我们同时使用传统多因子模型在同样的时间段进行选股, 与随机森林模型选股结果进行对比。传统多因子模型采用估值、盈利、成长、动量、反转、波动率、流动性、市值八大类因子建立线性模型, 采用 12 个月的移动平均方法预测因子未来收益。传统多因子模型具体建立方法可参照之前发表的报告《多因子模型研究之二: 收益预测模型》中的移动均值模型。

业绩归因模型: 为了具体对比两个模型在选股上的风格异同, 我们针对两类模型历史上选出的股票池, 运行业绩归因模型。业绩归因模型中的因子沿用了传统多因子模型的八大类因子。

业绩归因模型是用来衡量投资组合选股风格的模型。主要通过组合的因子暴露和因子收益来确定投资组合的主要收益来源。

其中因子暴露度的计算公式为：

$$(w - w_b)X_f^T$$

因子收益的计算公式为：

$$(w - w_b)X_f^T \cdot r_f$$

其中 w 为组合权重, X_f 为组合中股票的因子暴露矩阵, w_b 为基准指数的股票权重, r_f 为因子收益率。

通过业绩归因模型,我们可以看出模型选股在不同因子上的暴露与收益,从而解读模型选股风格。

3. 回测结果

3.1 针对沪深 300 的选股模型

通过统计针对沪深 300 的回测结果,可以看出,使用了随机森林多因子模型后,模型的收益和胜率相对传统多因子模型均有所提升,年化收益提升 1.75%,相对沪深 300 月度胜率提升 5%。

表 2: 沪深 300 选股模型历史回测结果

	累计收益	年化收益	波动率	最大回撤	夏普比率	胜率	换手率
MA	40.30%	4.11%	24.50%	45.80%	16.76%	54.46%	5.00
RandomForest	61.44%	5.86%	26.03%	49.78%	22.49%	59.41%	6.82
HS300	9.58%	1.09%	24.38%	40.56%	4.48%	--	--

数据来源: 渤海证券研究所、Wind

分年度对比两个选股模型的历史收益,可以看到 2010 年至 2012 年和 2016 年至 2018 年,随机森林模型表现略逊与传统多因子模型,2013 年至 2015 年,随机森林模型表现超越传统多因子模型。

表 3: 沪深 300 选股模型历史分年度收益统计结果


	2010	2011	2012	2013	2014	2015	2016	2017	2018
MA	10.7%	-29.4%	0.1%	-6.6%	33.8%	17.5%	-0.9%	27.6%	-3.4%
RandomForest	2.5%	-34.1%	1.4%	4.2%	64.3%	21.0%	-5.3%	27.1%	-5.5%
HS300	-2.4%	-25.0%	7.6%	-7.6%	51.7%	5.6%	-11.3%	21.8%	-12.9%

数据来源: 渤海证券研究所、Wind

请务必阅读正文之后的免责条款部分


从图中也可以看出，随机森林模型相对传统多因子模型的收益主要来自 2014 年市场风格转换期间，随机森林模型相对传统多因子模型更快的把握住了市场风格的切换，从而取得了超越指数的收益。

图 2：沪深 300 选股模型回测收益曲线



资料来源：Wind，渤海证券研究所

图 3：沪深 300 选股模型对冲基准回测收益曲线



资料来源：Wind，渤海证券研究所

通过业绩归因模型，我们考察了两类选股模型在不同因子上的风格暴露，可以发现传统多因子模型在因子暴露上的波动率明显大于随机森林模型，几乎为随机森林的一倍。在因子收益方面，传统多因子模型的收益主要来自于市值与估值因子，而随机森林模型的收益来源则相对更为平均。这说明在不加限制的情况下，传统

多因子模型选股风格可能会更加极端化。


表 4：沪深 300 选股模型因子统计结果

	市值	盈利	反转	动量	成长	流动性	波动率	估值
MA 因子均值	0.032	0.301	-0.388	0.005	0.488	-0.295	-0.078	0.357
MA 因子波动	2.023	1.603	1.262	1.899	1.984	1.309	0.487	1.423
MA 因子收益	0.169	0.090	0.092	-0.025	0.037	0.143	0.007	0.260
RF 因子均值	0.203	0.136	0.105	0.175	0.161	-0.110	-0.068	0.236
RF 因子波动	1.010	0.731	0.812	0.949	1.058	0.670	0.384	0.723
RF 因子收益	0.062	0.027	-0.095	0.143	0.028	0.049	0.024	0.205

资料来源：Wind，渤海证券研究所


接下来，我们详细考察了两类模型在各个因子上因子暴露时间序列。可以看出随机森林模型与传统多因子模型在市值、成长、盈利、估值、流动性、波动率因子上选股风格较为一致，传统多因子模型因子暴露绝对值普遍较高。针对动量（过去一年/近一月个股涨跌幅）与反转因子（近一月个股涨跌幅），两个模型的判断出现了一定分歧，结合上表，随机森林模型在反转因子上的因子收益为负，传统多因子模型在动量因子上的因子收益为负，可以看出随机森林模型更擅长针对反转因子这种较为短期的因子做判断，传统多因子模型更擅长针对动量因子这种更长期的因子做判断。

图 4：沪深 300 选股模型市值因子历史暴露



数据来源：Wind，渤海证券研究所


图 5：沪深 300 选股模型成长因子历史暴露



数据来源：Wind，渤海证券研究所


图 6：沪深 300 选股模型盈利因子历史暴露

图 7：沪深 300 选股模型估值因子历史暴露




数据来源: Wind、渤海证券研究所

图 8: 沪深 300 选股模型动量因子历史暴露




数据来源: Wind、渤海证券研究所

图 9: 沪深 300 选股模型反转因子历史暴露




数据来源: Wind、渤海证券研究所

图 10: 沪深 300 选股模型波动率因子历史暴露




数据来源: Wind、渤海证券研究所

图 11: 沪深 300 选股模型流动性因子历史暴露



数据来源: Wind、渤海证券研究所



数据来源: Wind、渤海证券研究所

3.2 针对中证 500 股票的选股模型

在针对中证 500 的回测结果中,可以看出,使用了随机森林多因子模型后,模型的波动率和胜率相对传统多因子模型均有所好转,波动率降低 1%,相对中证 500

请务必阅读正文之后的免责条款部分

月度胜率提高 6%。

表 5: 中证 500 选股模型历史回测结果

	累计收益	年化收益	波动率	最大回撤	夏普比率	胜率	换手率
MA	138.91%	10.90%	27.19%	44.63%	40.10%	56.44%	6.06
RandomForest	137.51%	10.82%	26.34%	46.07%	41.10%	62.38%	7.89
ZZ500	19.27%	2.12%	27.57%	47.65%	7.68%	--	--

数据来源: 渤海证券研究所、Wind

分年度对比两个选股模型的历史收益, 可以看到 2010 年至 2013 年, 随机森林模型表现略逊与传统多因子模型, 2013 年至 2018 年, 随机森林模型表现超越传统多因子模型。


表 6: 中证 500 选股模型历史分年度收益统计结果

	2010	2011	2012	2013	2014	2015	2016	2017	2018
MA	25.4%	-35.7%	8.3%	24.2%	36.7%	66.4%	5.6%	0.7%	-8.9%
RandomForest	18.6%	-35.2%	0.3%	21.6%	41.8%	68.1%	7.2%	8.0%	-8.1%
ZZ500	12.8%	-33.8%	0.3%	16.9%	39.0%	43.1%	-17.8%	-0.2%	-16.5%

数据来源: 渤海证券研究所、Wind


从图中也可以较为明显的看出这一趋势。2017 年以来, 传统多因子模型经历了较大回撤, 而随机森林模型依然保持上涨。随机森林模型相对传统多因子模型的收益主要来自 14 年和 17 年市场风格转换期间, 随机森林模型更快的把握住了市场风格的切换。

图 12: 中证 500 选股模型回测收益曲线



资料来源: Wind, 渤海证券研究所

图 13: 中证 500 选股模型对冲基准回测收益曲线



资料来源: Wind, 渤海证券研究所

通过业绩归因模型, 可以发现传统多因子模型在因子暴露上的波动率依然明显大于随机森林模型。在因子收益方面, 传统多因子模型的收益主要来自市值、流动性与波动率因子, 而随机森林模型的收益主要来自于流动性、波动率与估值因子。


表 7: 中证 500 选股模型因子统计结果

	市值	盈利	反转	动量	成长	流动性	波动率	估值
MA 因子均值	-0.479	0.451	-0.432	-0.045	0.953	-0.440	-0.198	0.315
MA 因子波动	2.295	1.390	1.017	1.410	1.478	1.177	0.873	1.053
MA 因子收益	0.376	0.115	0.146	0.056	0.162	0.227	0.232	0.100
RF 因子均值	-0.010	0.175	-0.076	0.009	0.317	-0.371	-0.169	0.315
RF 因子波动	0.873	0.776	0.860	1.092	1.085	0.863	0.344	0.784
RF 因子收益	0.018	0.048	-0.018	0.092	0.073	0.224	0.139	0.131

资料来源: Wind, 渤海证券研究所


观察两类模型在各个因子上因子暴露时间序列, 可以看出随机森林模型与传统多因子模型除市值之外的因子上选股风格均较为一致, 传统多因子模型因子暴露绝对值普遍较高。2010 年至 2013 年, 传统多因子模型在给予市值因子非常大的负向暴露, 而随机森林模型在市值因子的暴露上则十分保守, 这也可能是 2010 年至 2013 年间随机森林模型跑输传统多因子模型的主要原因。

图 14: 中证 500 选股模型市值因子历史暴露




数据来源: Wind、渤海证券研究所

图 15: 中证 500 选股模型成长因子历史暴露




数据来源: Wind、渤海证券研究所

图 16: 中证 500 选股模型盈利因子历史暴露




数据来源: Wind、渤海证券研究所

图 17: 中证 500 选股模型估值因子历史暴露




数据来源: Wind、渤海证券研究所

图 18: 中证 500 选股模型动量因子历史暴露




数据来源: Wind、渤海证券研究所

图 19: 中证 500 选股模型反转因子历史暴露




数据来源: Wind、渤海证券研究所

图 20: 中证 500 选股模型波动率因子历史暴露



数据来源: Wind、渤海证券研究所

图 21: 中证 500 选股模型流动性因子历史暴露



数据来源: Wind、渤海证券研究所

3.3 针对全体 A 股的选股模型

在针对全体 A 股的回测结果中,可以看出,使用了随机森林多因子模型后,模型的收益率和胜率相对传统多因子模型均有较大提高,年化收益率提高 3%,相对沪深 300 月度胜率提高 4%。

表 8: 全体 A 股选股模型历史回测结果

	累计收益	年化收益	波动率	最大回撤	夏普比率	胜率	换手率
MA	490.33%	23.49%	29.31%	34.90%	80.12%	63.37%	7.47
RandomForest	618.26%	26.40%	29.63%	37.57%	89.10%	67.33%	8.84
Wind 全 A	43.62%	4.40%	25.54%	44.57%	17.21%	52.48%	--
ZZ500	19.27%	2.12%	27.57%	47.65%	7.68%	49.50%	--
HS300	9.58%	1.09%	24.38%	40.56%	4.48%	--	--

数据来源: 渤海证券研究所、Wind

分年度对比两个选股模型的历史收益,可以看到随机森林模型相对传统多因子模型的收益主要来自 2013、2014 和 2017 年,随机森林模型更快的把握住了市场风格的切换。

表 9: 全体 A 股选股模型历史分年度收益统计结果


	2010	2011	2012	2013	2014	2015	2016	2017	2018
MA	39.9%	-22.8%	7.4%	26.3%	50.7%	149.1%	14.5%	-0.3%	-5.8%
RandomForest	34.4%	-25.7%	4.3%	41.4%	58.0%	149.9%	15.5%	4.4%	2.4%
Wind 全 A	1.9%	-22.4%	4.7%	5.4%	52.4%	38.5%	-12.9%	4.9%	-14.6%
ZZ500	12.8%	-33.8%	0.3%	16.9%	39.0%	43.1%	-17.8%	-0.2%	-16.5%
HS300	-2.4%	-25.0%	7.6%	-7.6%	51.7%	5.6%	-11.3%	21.8%	-12.9%

数据来源: 渤海证券研究所、Wind

请务必阅读正文之后的免责条款部分


从图中也可以较为明显的看出这一趋势。2017 年以来，传统多因子模型经历了一定回撤，而随机森林模型依然保持上涨。

图 22：全体 A 股选股模型回测收益曲线



资料来源：Wind，渤海证券研究所

图 23：全体 A 股选股模型对冲基准回测收益曲线



资料来源：Wind，渤海证券研究所

通过业绩归因模型，可以发现相对沪深 300 与中证 500 选股模型，全 A 选股模型的因子波动率均有了较大上涨，传统多因子模型在因子暴露上的波动率依然明显大于随机森林模型。在因子收益方面，传统多因子模型的收益主要来自市值、流动性与反转因子，而随机森林模型的收益主要来自于市值、流动性与估值因子。市值因子在两个模型的收益来源中均起到了最大的作用。


表 10: 全体 A 股选股模型因子统计结果

	市值	盈利	反转	动量	成长	流动性	波动率	估值
MA 因子均值	-0.158	0.561	-0.787	-0.345	0.995	-0.773	-0.042	0.368
MA 因子波动	3.432	2.433	1.742	1.803	2.590	1.967	0.929	1.602
MA 因子收益	0.599	0.247	0.445	-0.041	0.148	0.559	0.031	0.167
RF 因子均值	-0.412	0.093	-0.174	-0.169	0.106	-0.499	-0.127	0.410
RF 因子波动	2.287	0.839	0.893	1.377	1.157	1.034	0.415	0.887
RF 因子收益	0.386	0.033	0.074	0.016	0.022	0.386	0.070	0.203

资料来源: Wind, 渤海证券研究所


观察两类模型在各个因子上因子暴露时间序列, 可以看出随机森林模型与传统多因子模型在大部分因子上选股风格较为一致, 传统多因子模型因子暴露绝对值大幅高于随机森林模型, 在盈利、成长与反转因子上尤其明显。考虑到最后选股结果上传统多因子模型持续跑输随机森林模型, 其过于激进的因子暴露可能会带来不尽如人意的结果。

图 24: 全体 A 股选股模型市值因子历史暴露




数据来源: Wind, 渤海证券研究所

图 25: 全体 A 股选股模型成长因子历史暴露




数据来源: Wind, 渤海证券研究所

图 26: 全体 A 股选股模型盈利因子历史暴露




数据来源: Wind, 渤海证券研究所

图 27: 全体 A 股选股模型估值因子历史暴露




数据来源: Wind, 渤海证券研究所

图 28: 全体 A 股选股模型动量因子历史暴露




数据来源: Wind、渤海证券研究所

图 29: 全体 A 股选股模型反转因子历史暴露




数据来源: Wind、渤海证券研究所

图 30: 全体 A 股选股模型波动率因子历史暴露



数据来源: Wind、渤海证券研究所

图 31: 全体 A 股选股模型流动性因子历史暴露



数据来源: Wind、渤海证券研究所

4. 总结与未来研究方向展望

本篇报告中,我们针对沪深 300 成分股、中证 500 成分股与全体 A 股,分别使用机器学习中的随机森林算法构建了多因子选股模型,并与传统多因子模型进行对比。通过对比我们发现:

1. 在各个样本池中,随机森林模型的表现相比于传统多因子模型均有一定程度的提升,该提升主要是由随机森林模型在 2014 年与 2017 年市场转换时期表现出的相对传统多因子模型更强的灵活性导致的。所以,在市场风格不明显,未来趋势不清晰的情况下,更推荐使用随机森林模型,来控制未来市场风格切换的风险。
2. 通过业绩归因模型,我们考察了两类选股模型在不同因子上的风格暴露。在各个样本池中,传统多因子模型在各个因子暴露上的波动率均明显大于随机

森林模型。这说明在不加限制的情况下，传统多因子模型的选股风格可能会更加极端化。所以在使用传统多因子模型时，我们推荐与风险模型相结合，控制投资组合的整体风险（风险模型建立的具体细节可参见研报《多因子模型研究之三：风险模型与组合优化》）。

3. 各个样本池间横向比较，可以发现，股票池中的小市值股票越多（全 A>中证 500>沪深 300），模型选股结果的因子波动性越大，同时在市值因子的暴露也逐步上升。对市值因子的依赖是多因子模型一直面临的问题，在实际应用中，我们推荐对于市值因子做一定的风险敞口控制，以防止因子失效带来的大幅回撤风险。

未来，我们计划从以下三方面继续改善多因子模型：

1. 尝试使用更多机器学习算法，如 Boosting、SVM、神经网络等；
2. 将收益模型与风险模型相结合，进一步控制模型波动率；
3. 对于模型建立的细节进行进一步的完善，如因子预处理方法的选择对比等；
4. 将因子分析方法引入行业模型，分行业建立细分多因子模型，与行业轮动模型结合，形成自上而下的选股体系。

风险提示：随着市场环境变化，模型存在失效风险。

投资评级说明

项目名称	投资评级	评级说明
公司评级标准	买入	未来 6 个月内相对沪深 300 指数涨幅超过 20%
	增持	未来 6 个月内相对沪深 300 指数涨幅介于 10%~20%之间
	中性	未来 6 个月内相对沪深 300 指数涨幅介于-10%~10%之间
	减持	未来 6 个月内相对沪深 300 指数跌幅超过 10%
行业评级标准	看好	未来 12 个月内相对于沪深 300 指数涨幅超过 10%
	中性	未来 12 个月内相对于沪深 300 指数涨幅介于-10%-10%之间
	看淡	未来 12 个月内相对于沪深 300 指数跌幅超过 10%

重要声明： 本报告中的信息均来源于已公开的资料，我公司对这些信息的准确性和完整性不作任何保证，不保证该信息未经任何更新，也不保证本公司做出的任何建议不会发生任何变更。在任何情况下，报告中的信息或所表达的意见并不构成所述证券买卖的出价或询价。在任何情况下，我公司不就本报告中的任何内容对任何投资做出任何形式的担保，投资者自主作出投资决策并自行承担投资风险。我公司及其关联机构可能会持有报告中提到的公司所发行的证券并进行交易，还可能为这些公司提供或争取提供投资银行或财务顾问服务。我公司的关联机构或个人可能在本报告公开发表之前已经使用或了解其中的信息。本报告的版权归渤海证券股份有限公司所有，未获得渤海证券股份有限公司事先书面授权，任何人不得对本报告进行任何形式的发布、复制。如引用、刊发，需注明出处为“渤海证券股份有限公司”，也不得对本报告进行有悖原意的删节和修改。

请务必阅读正文之后的免责条款部分

渤海证券股份有限公司研究所

副所长（金融行业研究&研究所主持工作）

张继袖

+86 22 2845 1845

副所长

谢富华

+86 22 2845 1985

计算机行业研究小组

王洪磊（部门副经理）

+86 22 2845 1975

朱晟君

+86 22 2386 1319

王磊

汽车行业研究小组

郑连声

+86 22 2845 1904

张冬明

+86 22 2845 1857

环保行业研究

张敬华

+86 10 6810 4651

刘蕾

+86 10 6810 4662

电力设备与新能源行业研究

刘瑞

+86 22 2386 1670

刘秀峰

+86 10 6810 4658

医药行业研究小组

张冬明

+86 22 2845 1857

赵波

+86 22 2845 1632

甘英健

通信&电子行业研究小组

徐勇

+86 10 6810 4602

餐饮旅游行业研究

刘瑞

+86 22 2386 1670

杨旭

+86 22 2845 1879

证券行业研究

张继袖

+86 22 2845 1845

洪程程

+86 10 6810 4609

金融工程研究&部门经理

崔健

+86 22 2845 1618

权益类量化研究

李莘泰

+86 22 2387 3122

宋旻

+86 22 2845 1131

衍生品类研究

祝涛

+86 22 2845 1653

李元玮

+86 22 2387 3121

郝惊

+86 22 2386 1600

债券研究

王琛睿

+86 22 2845 1802

冯振

+86 22 2845 1605

夏捷

+86 22 2386 1355

基金研究

刘洋

+86 22 2386 1563

流动性、战略研究&部门经理

周喜

+86 22 2845 1972

策略研究

宋亦威

+86 22 2386 1608

杜乃璇

+86 22 2845 1945

宏观研究

张杨

博士后工作站

朱林宁 资产配置

+86 22 2387 3123

综合质控&部门经理

齐艳莉

+86 22 2845 1625

机构销售•投资顾问

朱艳君

+86 22 2845 1995

风控专员

白骐玮

+86 22 2845 1659

合规专员

任宪功

+86 10 6810 4615

渤海证券研究所

天津

天津市南开区宾水西道 8 号

邮政编码：300381

电话：(022) 28451888

传真：(022) 28451615

北京

北京市西城区西直门外大街甲 143 号 凯旋大厦 A 座 2 层

邮政编码：100086

电话：(010) 68104192

传真：(010) 68104192

渤海证券研究所网址：www.ewww.com.cn