

“逐鹿” Alpha 专题报告（二十二）

——Factor Zoo II 基本面因子挖掘统一框架

核心观点

本文我们将之前系列基本面因子挖掘的算法进行了统一的整合及优化，构建出了基本面因子挖掘统一框架，相比于传统的基本面因子挖掘方法，我们提出的框架能够适用于各类主观及自动化因子挖掘方案，并且对于因子的量纲及频率进行了自动化处理，确保了生成因子的合法性和有效性，对因子的适应度也进行了改进，加入了相关性的惩罚项，能够生成更加多样的基本面因子。

主要内容

简介

在先前的报告系列中，我们已经探究了众多因子挖掘的技术与方法。这些包括但不限于基于枚举法的 OPENFE，以启发式算法为核心的 AlphaZero，以及将启发式与枚举法相结合、并融合领域知识的因子挖掘算法，皆适用于多种类型因子挖掘的具体场景。本文我们将之前系列基本面因子挖掘的算法进行了统一的整合及优化，构建出了基本面因子挖掘统一框架。

框架

在量化投资领域，基本面因子的分析面临诸多挑战：数据格式的多样性、更新频率的差异、缺失值的普遍性、数据维度的复杂性、因子间的高相关性，以及数据发布与公告日期的不一致性等。针对这些问题，本文提出了一种创新的统一基本面因子框架。该框架包括了因子生成，因子计算，因子验证，因子进化，因子筛选等模块，对每个模块都进行了优化，使其能够更加高效合理的挖掘基本面因子。该框架不仅整合了多种因子生成技术，还能够有效处理不同频率和量纲的数据融合问题。通过这一方法，我们能够提炼出适应性强、低相关性的优质基本面因子。

结论

在本篇研究中，我们在先前系列因子挖掘工作的基础上，精心构建了一个全面的基本面因子挖掘统一框架，该框架不仅整合了多种因子生成技术，并且能够自动优化基本面因子的频率和量纲。在此框架中融入了一系列常用算子，包括元素算子、时序算子和截面算子等，此外，为了进一步提升计算效率，我们在框架的底层采用了 cython 与流式计算技术的结合，这显著提高了因子计算的速度和性能。在因子筛选阶段，我们特别引入了因子相关性惩罚机制。这一机制的运用有效促进了因子的多样性，确保了最终生成的因子集合在保持低相关性的同时，也能捕捉到市场的有效信息。

金融工程研究

姚紫薇

yaoziwei@csc.com.cn

SAC 编号: S1440524040001


王超

wangchaodcq@csc.com.cn

SAC 编号: S1440522120002

发布日期: 2024 年 08 月 06 日

市场表现



相关研究报告

目录

一、简介.....	1
二、相关工作.....	1
2.1 AlphaZero	1
2.2 OpenFE.....	2
2.3 领域知识	4
三、框架.....	4
3.1 因子生成	5
3.2 因子计算	5
3.3 因子验证	8
3.4 因子筛选	9
3.5 因子进化	10
四、实验设置.....	12
五、结果.....	13
六、总结.....	15
风险分析.....	16

表目录

表 1:风格因子结构.....	3
表 2:算子集合.....	6
表 3:数据属性.....	12

图目录

图 1: AutoML-Zero 算法.....	2
图 2: OpenFE 结构	3
图 3:领域知识因子挖掘框架.....	4
图 4:因子挖掘框架.....	5
图 5: ts_regression_slope cython+流式计算代码.....	8
图 6:树状表达式	11
图 7:逆波兰表达式 (C)	11
图 8:程序表达式	11
图 9:因子一 IC.....	13
图 10:因子一分组收益	13
图 11:因子二 IC.....	14
图 12:因子二分组收益	14
图 13:因子三 IC.....	15
图 14:因子三分组收益	15

一、简介

本文是 Factor Zoo 系列报告的第二篇。Factor Zoo 旨在深入挖掘并剖析各类 Alpha 因子的表现特征，继承并扩展了我们先前 Model Zoo 系列的研究范畴。在这两大系列的研讨中，我们致力于对广泛的模型与因子进行细致的考察与大规模的检验，力求提炼出宝贵的经验规律，从而为未来因子与模型的创新发展奠定坚实的基础。

在先前的报告系列中，我们已经探究了众多因子挖掘的技术与方法。这些包括但不限于基于枚举法的 OPENFE，以启发式算法为核心的 AlphaZero，以及将启发式与枚举法相结合、并融合领域知识的因子挖掘算法，皆适用于多种类型因子挖掘的具体场景。

本文我们将之前系列基本面因子挖掘的算法进行了统一的整合及优化，构建出了基本面因子挖掘统一框架，相比于传统的基本面因子挖掘方法，我们提出的框架能够适用于各类主观及自动化因子挖掘方案，并且对于因子的量纲及频率进行了自动化处理，确保了生成因子的合法性和有效性，对因子的适应度也进行了改进，加入了相关性的惩罚项，能够生成更加多样的基本面因子。

二、相关工作

在本篇研究中，我们基于先前发布的逐鹿因子挖掘系列报告进行了全面的整合与进一步的优化。在深入探讨本文的研究内容之前，让我们先简要回顾一下我们在之前系列报告中所开展的工作。


2.1 AlphaZero

AlphaZero 是我们将 google 的 AutoML-Zero 模型应用于因子挖掘领域，结合实际情况对模型做了相应的改进，构建的因子挖掘框架。

AutoML-Zero 是基于程序结构的个体结合正则化进化算法的方式，将程序内的代码不断变异进化，最终生成目标程序。在原论文中，作者通过在 CIFAR-10 的数据集上训练，发现算法能够不断进化，从线性模型，到损失函数，梯度下降，激活函数等等，实现了完整的 MLP 过程。

在 AutoML-Zero 的基础上，我们进一步发展并构建了 AlphaZero 框架。与传统的遗传编程以及 AutoML-Zero 相比，AlphaZero 在提升因子挖掘效率和增强因子可解释性方面做出了显著的优化和改进。首先，我们对所有数据采用了量纲化处理，避免了在因子挖掘中经常出现的不同量纲之间的因子运算，并且要求最终生成的因子为无量纲因子，这样使得因子可解释性问题有所缓解。其次，我们对合成因子的长度进行了严格控制，以避免因子计算过于复杂，从而减少过拟合的风险。最后，我们引入了热启动机制、退化变异以及灾难算法等策略。这些策略不仅提高了算法的进化效率，而且在正则化的基础上增加了物种的多样性，促进了因子的分散度，从而提高了结果的鲁棒性和创新性。

图 1: AutoML-Zero 算法



数据来源: AutoML-Zero: Evolving Machine Learning Algorithms From Scratch, 中信建投

2.2 OpenFE

OpenFE 是一个基于枚举法的 Expand-And-Reduce 框架, 首先通过基础特征以及算子的排列组合构建具有一定结构的风格因子。而后通过两步的筛选步骤, 对因子进行筛选, 保留最终特征重要性最高的因子。

图 2: OpenFE 结构




Figure 1: The overview of OpenFE.

数据来源: OpenFE: Automated Feature Generation with Expert-level Performanc, 中信建投

在构造因子时,我们借鉴已有的成熟因子结构,例如 ROE,PE 等,将其拓展为二阶因子结构,并且限制分子分母的数据来源,确保其具有清晰的金融学含义,采用枚举法的方法生成所有可能的因子形式,生成了共计约 70 万因子。

在处理大量生成的因子时,传统因子检验方法的效率往往不尽人意。为了提高效率,OpenFE 采用了一种两阶段的检验流程:

第一步:应用连续二分法进行初步筛选。在面对大量因子时,该方法首先使用少量数据进行快速筛选,以减少因子的数量。随着筛选的进行,逐步增加用于检验的数据量,并重复这一过程。这一步骤将持续进行,直到因子数量降至符合特定要求的水平,从而形成一个单因子效果显著的因子集合。

第二步:进行多因子检验。将第一步筛选出的因子集合输入模型进行全面训练,以深入分析每个因子的有效性,并且剔除了因子相关性的影响。最终识别并提炼出最终表现优异的因子列表。

表 1:风格因子结构


风格	因子结构	说明
杠杆因子	$CSRANK((a \pm b)/(c \pm d))$	$a, b, c, d \in$ 资产负债表
收益因子	$CSRANK((a \pm b)/(c \pm d))$	$a, b \in$ 损益表 $c, d \in$ 资产负债表
质量因子	$CSRANK((a \pm b)/(c \pm d))$	$a, b \in$ 损益表 $c, d \in$ 现金流量表
估值因子	$CSRANK((a \pm b)/market_value)$	$a, b \in$ 损益表/现金流量表/资产负债表
成长因子	$CSRANK(x * f(a) \pm y * f(b))$	$a, b \in$ 损益表/现金流量表/资产负债表, $f \in$ QOQ/YOY, $x, y \in [0, 5]$

资料来源: 中信建投证券

2.3 领域知识

领域知识是将进化算法作为专家，通过自动化因子挖掘的方式生成优秀的因子种群，对优秀种群做进一步的分析，包括剪枝，基因结构分析等，从种群中提取占比最高的基因以及结构，这些基因是构建优秀因子组合的基础。利用这些精选的基因和结构，我们可以通过人工合成的方式创造新的因子组合，这些新合成的因子将经过严格的检验和筛选流程，以确保它们的有效性。

图 3:领域知识因子挖掘框架



数据来源：中信建投证券

三、框架


结合之前的研究工作，本文提出了基本面因子挖掘的统一框架，旨在解决基本面因子挖掘中存在的诸多问题。

在量化投资领域，基本面因子的分析面临诸多挑战：数据格式的多样性、更新频率的差异、缺失值的普遍性、数据维度的复杂性、因子间的高相关性，以及数据发布与公告日期的一致性。

传统在构建基本面因子时，通常是按照发布日期将因子转换为固定频率，或者在所有公告发布完成后在固定日期构建因子，这两种方法限制了基本面因子挖掘方法的多样性和有效性。

针对这些问题，本文提出了一种创新的统一基本面因子框架。该框架包括了因子生成，因子计算，因子验证，因子进化，因子筛选等模块，对每个模块都进行了优化，使其能够更加高效合理的挖掘基本面因子。该框架不仅整合了多种因子生成技术，还能够有效处理不同频率和量纲的数据融合问题。通过这一方法，我们能够提炼出适应性强、低相关性的优质基本面因子。

图 4:因子挖掘框架



数据来源：中信建投证券

3.1 因子生成

在生成基本面因子时，我们采用了以下三种策略：

随机法：这种方法通过随机方式构造因子结构，主要用于启发式算法中的种群初始化。在生成个体时，我们会限制其结构的复杂度以及量纲的合法性，以确保因子具有简洁性并保持较高的可解释性。

枚举法：与之前 openfe 算法生成因子一致，在因子生成过程中通过设定因子结构的约束条件，如 $(a+b/c+d)$ ，在给定的子空间内进行全局搜索，以期找到局部最优解。

领域知识：这种方法依赖于专家的主观经验，通过专业知识构造一系列基本面因子。然后利用启发式算法不断优化这些因子，结合剪枝和基因结构分析等技术，筛选出适应度较高的基因及个体。接着，通过枚举法合成新的因子个体，并从中挑选出表现优异的个体。

3.2 因子计算

在本框架中，因子计算是其核心功能。正如之前讨论的，基本面数据面临多种挑战。为了灵活应对这些问题，我们构建了一个双层的因子计算结构。具体来讲，对于每一个数据，我们会设置其量纲以及频率属性，在进行因子计算时，会自动根据其量纲以及频率进行处理，确保运算的合法性。

第一层 主要负责原始财务数据的处理。这包括资产负债表、现金流量表、利润表以及各种财务指标。为了确保数据在时间序列上的可比性，我们分别将现金流量表和利润表等时间段数据统一转换为单季度数据。这一层不仅能够处理截面数据，更重要的是能够处理财务数据的时序数据，例如滚动年度（TTM）、同比（YOY）、环比（QOQ）算子等。在计算这些时序数据时，我们会按报告期的顺序对数据进行排序和处理。

第二层 则专注于不同频率因子的结合。例如，在计算市盈率（PE）因子时，分子端的“E”代表季度财务

数据，而分母端的“P”代表日频数据。在处理不同频率的数据时，我们会首先对低频数据按照信息发布日期进行隐式的频率转换（PIT），将其转换为高频数据，然后再与其他高频数据进行计算。

在进行数据计算时，还需注意数据的量纲差异。例如，营收、利润等财务数据具有货币单位的量纲，而一些财务指标如净资产收益率（ROE）、净利润同比增长率则没有量纲。具有相同量纲的数据可以进行常规的数学运算，如加减除等，根据规则得到相应量纲的结果。对于不同量纲的数据，只能进行特定的运算，例如货币单位的数据与无量纲的数据之间只能进行乘法运算，结果仍为货币单位的数据。

尽管市值也具有货币单位的量纲，但将其与营收等货币单位的数据直接进行加法或减法运算显然是不合适的。因此，我们会为这两类数据设置不同的量纲，并仅允许它们之间进行除法运算。这种处理方式确保了计算的准确性和合理性。

在构建算子时，除了常规的运算定义，同样会设置算子输入和输出的量纲要求，具体的定义方式如下表所示，通过这些算子定义，能够避免构造出不符合逻辑的基本面因子。

表 2:算子集合

算子	解释	量纲要求
元素运算符		
add(m1, m2)	$m1+m2$	输入相同量纲，输出不改变量纲
sub(m1, m2)	$m1-m2$	输入相同量纲，输出不改变量纲
div(m1, m2)	$m1/m2$	输入相同量纲，输出无量纲
mul(m1, m2)	$m1*m2$	输入为不同量纲，输出为带量纲
时间序列运算符		
ts_mean(m,v)	过去 v 期 m 的平均值	输出不改变量纲
ts_std(m,v)	过去 v 期 m 的标准差	输出不改变量纲
ts_delay(m,v)	m 滞后 v 期	输出不改变量纲
ts_delta(m,v)	m 与过去 v 期的差值	输出不改变量纲
ts_pct(m,v)	m 与过去 v 期的变化率	输出无量纲
ts_max(m,v)	过去 v 期 m 的最大值	输出不改变量纲
ts_min(m,v)	过去 v 期 m 的最小值	输出不改变量纲
ts_min_max_diff(m,v)	过去 v 期 m 的最大值与最小值的差	输出不改变量纲
yoy(m)	m 的同比值	输出无量纲
qoq(m)	m 的环比值	输出无量纲
ttm(m)	m 的 TTM 值	输出不改变量纲
ts_slope(m,v)	过去 v 期 m 的斜率	输出不改变量纲
ts_resi(m,v)	过去 v 期 m 的残差	输出不改变量纲
ts_rsquare(m,v)	过去 v 期 m 的 r^2	输出无量纲
ts_regression_slope(m1,m2,v)	过去 v 期 m1 对 m2 回归的斜率	输入相同量纲，输出无量纲

ts_regression_resi(m1,m2,v)	过去 v 期 m1 对 m2 回归的残差	输入相同量纲，输出不改变量纲
ts_regression_rsquare (m1,m2,v)	过去 v 期 m1 对 m2 回归的 r2	输入相同量纲，输出无量纲
横截面运算符		
cs_norm(m)	m 的横截面标准化	输出无量纲
cs_rank(m)	m 的横截面排序	输出无量纲

资料来源：中信建投

其中 m 代表底层数据，包括三大财务报表，财务指标，一致预期，市值等，对于这些原始数据，我们会为其定义频率和量纲属性。在进行数据分析和运算时，将依据既定的规则对这些属性进行自动处理。v 代表常数项，取值为 1, 2, 4, 8, 12，对于季频因子，常数项单位为季度，取值从一个季度到三年，如果为日频因子，单位为月，时间长度从一个月到一年。

在进行不同频率数据的结合时，需要不断在发布日期和公告日期之间排序，以及不同日期之间的合并，利用 pandas 能够灵活的实现这些操作，而对于底层复杂运算，尤其是时序滚动算子，采用一般的 groupby+rolling apply 的计算复杂度为 $O(M \cdot T \cdot N)$ ，M 为股票数量，T 为时间长度，N 正比于 Rolling 的长度，计算相率非常慢。为提升计算性能，我们特别针对一些较为复杂的算子，如斜率 (slope)、残差 (resi)、rsquare 等，采取了与 Factor Zoo I 相似的底层优化策略。通过结合 Cython 与流式计算技术，将计算复杂度降为 $O(B \cdot T)$ ，能够显著增强计算速度，从而实现更高效的数据处理。

以 ts_regression_slope 算子为例，如果使用传统的 scipy.stats.linregress 函数，对一只股票两个因子间进行 1000 次 T 为 12 的滚动回归，耗时约 8.15 秒，采用 cython+流式计算技术，耗时约 0.07 秒，效率提升 116 倍。其中 cython 带来的提升约为 9.6 倍，流式计算带来的提升约为 12 倍。函数的核心定义如下：

图 5: ts_regression_slope cython+流式计算代码

```
cdef class RollingRegression(Rolling):  
    """Rolling regression with intercept"""  
    cdef double x_sum  
    cdef double y_sum  
    cdef double x2_sum  
    cdef double xy_sum  
    cdef deque[double] x_barv  
  
    def __init__(self, int window):  
        super(RollingRegression, self).__init__(window)  
        self.x_sum = 0  
        self.y_sum = 0  
        self.x2_sum = 0  
        self.xy_sum = 0  
        for i in range(window):  
            self.x_barv.push_back(NAN)  
  
    cdef tuple update2(self, double x_val, double y_val):  
        self.x_barv.push_back(x_val)  
        self.y_barv.push_back(y_val)  
  
        cdef double x_front = self.x_barv.front()  
        cdef double y_front = self.y_barv.front()  
  
        if not isnan(x_front) and not isnan(y_front):  
            self.x_sum -= x_front  
            self.y_sum -= y_front  
            self.x2_sum -= x_front * x_front  
            self.xy_sum -= x_front * y_front  
        else:  
            self.na_count -= 1  
  
        self.x_barv.pop_front()  
        self.y_barv.pop_front()  
  
        if isnan(x_val) or isnan(y_val):  
            self.na_count += 1  
            # return NAN  
        else:  
            self.x_sum += x_val  
            self.y_sum += y_val  
            self.x2_sum += x_val * x_val  
            self.xy_sum += x_val * y_val  
  
        cdef int N = self.window - self.na_count  
  
        cdef double numerator = N * self.xy_sum - self.x_sum * self.y_sum  
        cdef double denominator = N * self.x2_sum - self.x_sum * self.x_sum  
        cdef double slope = numerator / denominator  
        cdef double intercept = (self.y_sum - slope * self.x_sum) / N  
  
        return slope, intercept  
  
    cdef double residual(self, double x_val, double y_val):  
        cdef double slope, intercept  
        slope, intercept = self.update2(x_val, y_val)  
        return y_val - (slope * x_val + intercept)  
  
    cdef double r_squared(self, double x_val, double y_val):  
        cdef double slope, intercept  
        slope, intercept = self.update2(x_val, y_val)  
        cdef int N = self.window - self.na_count  
        cdef double y_mean = self.y_sum / N  
        cdef double ss_tot = 0.0  
        cdef double ss_res = 0.0  
        cdef double val  
        cdef int i  
        for i in range(self.y_barv.size()):  
            val = self.y_barv[i]  
            if not isnan(val):  
                ss_tot += (val - y_mean) ** 2  
                ss_res += (val - (slope * self.x_barv[i] + intercept)) ** 2  
        return 1 - (ss_res / ss_tot) if ss_tot != 0 else NAN
```

数据来源：中信建投证券

3.3 因子验证

因子验证模块主要用于计算因子的有效性或者适应度，评估因子有效性通常有两种方法，包括因子信息系数（Factor Information Coefficient, IC）和非线性特征重要性评估。

因子 IC 是一种计算因子预测能力的方法，它通过比较因子值与未来收益率之间的线性关系来衡量因子的预测能力。这种方法能够直观地反映出因子在预测市场表现方面的有效性。

非线性特征重要性评估则是一种更为复杂的方法，它考虑了因子在模型中的非线性作用，是机器学习中用于理解模型决策过程和优化模型性能的关键技术，常用的算法包括基于树模型的特征重要性计算，SHAP 值，排序重要性等，用于评估每个因子对模型整体性能的贡献。

对于基本面因子而言，我们更加注重因子的可解释性，因此本文主要采用因子 IC 来考察因子有效性，因子的收益率目标为第二天开盘价到一个月以后收盘价所对应的收益率。

3.4 因子筛选

因子筛选的主要目的是从批量生成的因子中筛选出效果较好的一些因子，个体筛选的算法有很多，常用的算法包括最优个体法，轮盘法以及锦标赛法。

最优个体法通过从因子种群中挑选出适应度得分最高的 N 个因子。这种方法的优势在于其高效性，能够迅速识别出表现最佳的因子。然而，它也存在一些局限性，特别是在进化算法中，这种方法可能会减少个体的多样性，从而增加陷入局部最优解的风险，同时也可能导致筛选出的因子之间存在过高的相关性。

轮盘法根据因子的适应度来确定其被选中的概率。这种方法有助于分散因子选择的集中度，但同时也存在一定的局限性，因为单个因子被选中的概率较低，这可能会降低最优因子被选中的可能性。此外，在进化算法中应用轮盘法可能会降低算法的进化速度。

锦标赛法是一种更为灵活的筛选方法。它首先在因子种群中随机选取 k 个个体，然后在这些因子中选择适应度最高的一个。这个过程重复进行，直到达到所需的个体数量。锦标赛法实际上是最优个体法和轮盘法的一般形式，通过调整 k 的值，可以在因子的适应度和群体多样性之间实现平衡。当 $k=1$ 时，锦标赛法退化为轮盘法；当 k 等于种群大小时，锦标赛法等价于最优个体法。

本文中我们采用锦标赛法对候选个体进行筛选，其中参数 k 设定为 3。这种方法虽然能在一定程度上缓解因子多样性的问题，但并不能从根本上解决这一问题。在进化算法中，随着迭代次数的增加，种群的整体适应度得以提升，然而，那些与现有因子相关性较低但自身适应度不高的因子，依然面临着难以被选入下一代的风险。

在先前的研究中，我们使用了退化变异和灾难算法，通过删除特定基因或个体来增强种群的多样性。在本研究中，我们采纳了一种更为直接和高效的策略：在适应度计算中引入了惩罚项。通过调整相关性惩罚后的适应度，我们能够筛选出既具有较高适应度又保持较低相关性的因子。适应度的计算公式定义如下：

$$fitness = IC * (1 - \mu * (1 - max_{corr}))$$

其中 μ 为惩罚系数，其取值范围从 0 到 1， μ 值越大，对相关性的惩罚也就越重，这有助于提升种群的多样性，但同时可能会牺牲一定的整体有效性，本文取 1/2。 max_{corr} 的计算方法如下：

$$max_{corr} = \max(corr_{population}, corr_{factor\ pool})$$

max_{corr} 由两部分计算得到， $corr_{population}$ 表示个体与种群中其他个体的相关性， $corr_{factor\ pool}$ 表示个体与 factor pool 中的个体相关性，其中 factor pool 是已经经过筛选保留得到的因子池。

通过引入惩罚项，如果新生成的因子与现有因子的相关性过高，其适应度将被有效降低，从而减少其被选中的可能性，这有助于我们发现新的、具有潜力的因子。

需要注意的是，如果直接计算因子间的截面相关性，其计算复杂度非常高，时间复杂度为 $O(MTP^2)$ ，其中 T 为时间长度， P 为种群中个体数量， M 为股票数量。为了提高计算效率，我们采用了因子 IC 时间序列的相关性来替代直接的因子值相关性计算，其计算效率为 $O(TP^2)$ ，与原始的因子值相关性计算相比，效率提升 M (~ 5000) 倍。

然而，因子值的相关性与因子 IC 的相关性之间可能会存在显著差异。尽管某些因子值本身可能不表现出强烈的相关性，但市场风格的趋同性可能导致因子 IC 的相关性显著高于因子值的相关性。以营收和净利润为例，尽管它们因子值的相关性为 0.56，但它们的因子 IC 相关性却高达 0.88。

从现实问题出发，我们更倾向于推荐使用 IC 相关性或因子收益率相关性的方法来评估因子之间的相关性。仅仅关注因子值的相关性可能只能确保我们的投资组合在表面上看起来是分散的，但这些投资标的可能市场上表现出相似的行为，这在本质上并未能有效分散风险。相反，通过分析因子表现的相关性，我们可以从实际的市场表现角度出发，更有效地实现风险的分散。

3.5 因子进化

因子进化为可选步骤，此步骤专门用于优化和改进因子，对于进化算法而言，随机初始化生成的种群中不一定存在适应度高的个体，因此需要不断进化，使种群的适应度提高，从而筛选出效果更好的个体。


因子进化的原理主要是通过父代间的交叉和变异不断生成新的个体种群，再筛选出其中适应度较高的个体，从而使得整个种群的适应度不断增加，达到进化的目的。

在进化算法的应用中，将因子的字符串表达式表示为结构化表达式是至关重要的一步。通常，将因子解析为树状表达式是一种广泛采用的方法。除了树结构，还可以采用逆波兰表达式、程序表达式等其他形式。这三种表达方式各有千秋，能够相互转换，并且各自具有独特的优势：

- **逆波兰表达式** 以其结构简洁著称，在进化过程中，通常通过添加或修改最后一个 token 来迭代生成新的因子。这种方法依赖于现有路径，因此搜索空间相对较小，但可以更精确地控制进化方向。
- **树状表达式** 则提供了清晰的层次结构，在进化时可以在叶节点或算子上进行操作。与逆波兰表达式相比，树状表达式提供了更广阔的搜索空间，有助于探索更多可能的因子组合。
- **程序表达式** 则提供了极高的灵活性，它允许在没有显式关联关系的代码片段之间进行操作。在进化过程中，如果不施加人为限制，可以在全搜索空间内进行探索。这种灵活性使得程序表达式在 AutoML-Zero 等框架中，被用来寻找全新的基础算法。然而，在全空间内进行搜索也意味着算法效率较低，在大规模搜索时需要一定的硬件资源。


本文选择采用树状表达式来构建因子，树结构的优势在于，首先，能够清晰展示因子之间的关系和层次，使得结构易于理解 and 操作。其次，针对树结构的相关算法已经相当成熟，这为因子的进一步处理和优化提供了便利。此外，树结构的灵活性也使得算法能够更加高效地处理各种复杂的因子表达式。

图 6:树状表达式



数据来源：中信建投证券

图 7:逆波兰表达式 (C)



数据来源：Generating Synergistic Formulaic Alpha Collections via Reinforcement Learning, 中信建投证券

图 8:程序表达式

```
# sX/vX/mX = scalar/vector/matrix at address X.
# "gaussian" produces Gaussian IID random numbers.
def Setup():
    # Initialize variables.
    m1 = gaussian(-1e-10, 9e-09) # 1st layer weights
    s3 = 4.1 # Set learning rate
    v4 = gaussian(-0.033, 0.01) # 2nd layer weights
def Predict(): # v0=features
    v6 = dot(m1, v0) # Apply 1st layer weights
    v7 = maximum(0, v6) # Apply ReLU
    s1 = dot(v7, v4) # Compute prediction
def Learn(): # s0=label
    v3 = heaviside(v6, 1.0) # ReLU gradient
    s1 = s0 - s1 # Compute error
    s2 = s1 * s3 # Scale by learning rate
    v2 = s2 * v3 # Approx. 2nd layer weight delta
    v3 = v2 * v4 # Gradient w.r.t. activations
    m0 = outer(v3, v0) # 1st layer weight delta
    m1 = m1 + m0 # Update 1st layer weights
    v4 = v2 + v4 # Update 2nd layer weights
```

数据来源：AutoML-Zero: Evolving Machine Learning Algorithms From Scratch, 中信建投证券

在进化过程中，父代个体通过子树交换和子树变异产生新的子代，两者的概率分别设置为 0.6 和 0.3，以确保算法在探索新的可能性和保持已有优势之间取得平衡。在实际的进化过程中，我们不仅保留最终的 hof (hall of

fame) 中的个体, 而且对中间过程中产生的个体进行缓存。当计算新变异个体的适应度时, 如果该个体已存在于缓存中, 我们可以直接提取其适应度值, 从而有效避免重复计算, 有效提升运算效率。

在应用进化算法时, 我们可以在初始因子生成阶段引入热启动策略。热启动的核心思想是将之前筛选得到的优异个体纳入初始化种群, 这样做可以显著加速种群的进化进程, 提高整体的搜索效率。通过这种方式, 算法能够更快地逼近最优解。

四、实验设置

在本文中, 我们采用的数据如前文所述, 主要包括了三大财务报表, 财务指标, 一致预期以及市值等。对于这些基础数据, 如果缺失值超过 20% 则予以剔除, 最终共计 201 个字段, 对每个字段都会赋予相应的量纲和频率, 用于后续计算。数据属性样例如下:

表 3: 数据属性

字段名	中文名	量纲	频率
tot_oper_rev	营业总收入	元	Q
s_fa_roe	净资产收益率	无	Q
val_mv	总市值	市值	D
est_total_profit_fy1	未来一年一致预期利润总额	元	D

资料来源: WIND, 中信建投证券

数据为全市场股票从 2014 年至 2024 年 5 月底的所有数据, 在计算因子有效性时, 预测的目标为第 2 天的开盘价到 21 天后收盘价的收益率, 每日滚动计算有效性, 确保了因子的可交易性, 避免路径依赖。

在因子生成时, 主要采用随机化+热启动的方式, 结合进化算法不断对因子进行改进。热启动因子的来源包括之前报告中构建的因子, 以及在当前研究过程中发现的表现出色因子。在初始化阶段, 我们采用 "half-half" 策略。具体来说, 一半的初始个体是通过 genFull 方法生成的, 这种方法确保了所有叶节点的深度与树的整体深度相等, 从而生成了结构完整的因子。另一半个体则是通过 genGrow 方法生成的, 这种方法允许至少有一个叶节点达到树的最大深度, 同时其他叶节点可以有不同的深度, 增加了因子的多样性。

在本研究中, 我们设定种群大小为 1000, 意味着每一代种群中包含了 1000 个的因子。进化轮数设定为 20, 旨在避免因子结构变得过于复杂, 确保模型的可解释性和实用性。在算法运行过程中, 中间生成的因子, 只要其信息系数 (IC) 超过 0.04, 就会被自动保存。算法运行结束后, 将保存下来的优秀因子按照它们的 IC 值进行排序, 并计算它们之间的两两相关性。如果两个因子之间的相关性超过 0.6, 我们会选择剔除 IC 值较低的因子, 以此来构建候选因子池。

最后再将候选因子池与现有的因子池进行对比, 计算它们之间的两两相关性。如果在候选因子中存在与现有因子池中因子相关性较低的新因子, 这些新因子将被纳入现有的因子池。如果候选因子与现有因子池中的因

子存在高相关性（超过 0.6），并且候选因子的表现优于现有因子，则进行替换；否则保持现有因子池不变，不做任何调整。

五、结果

在对最终的因子经过严格的有效性和相关性筛选之后，我们得到了以下因子：

因子一： $ts_std(add(add(s_fa_yoyequity, s_qfa_optogr), s_qfa_yoysales), 12)$


因子解释：12 期波动率（相对年初增长率-归属母公司的股东权益（%）+单季度.营业利润 / 营业总收入+单季度.营业收入同比增长率（%））

因子一主要表示公司增长和利润率的长期波动率，波动越小，未来收益越高

因子 IC：-0.0467

因子 IR：1.9615

图 9:因子一 IC



数据来源：WIND, 中信建投证券

图 10:因子一分组收益



数据来源：WIND, 中信建投证券

因子二：

$ts_regression_resi(add(net_cash_flows_oper_act, s_stm_bs)/ttm(s_fa_fcff), add(div(tot_shrhdr_eqy_excl_min_int, val_mv), qoq(add(tot_oper_cost2, oper_rev))), 4)$


因子解释：4 期回归残差（（经营活动产生的现金流量净额+固定资产合计）/TTM（企业自由现金流量（FCFF），（股东权益合计（不含少数股东权益）/总市值 + 环比（营业总成本 2+营业总收入））

因子二主要表示估值指标的可解释性，当第一项的增长高于第二项的增长时，未来收益越高。

因子 IC: 0.0567


因子 IR: 1.4513

图 11:因子二 IC



数据来源: WIND, 中信建投证券

图 12:因子二分组收益



数据来源: WIND, 中信建投证券

因子三: $\text{div}(\text{ts_mean}(\text{surplus_rsrv}, 8), \text{val_mv})$


因子解释: 8 期平均 (盈余公积金) / 总市值

因子三是类 PE 的估值因子, 采用了盈余公积金取代了 PE 中的净利润, 该因子值越大, 未来收益越高。

因子 IC: 0.0537


因子 IR: 1.2734

图 13:因子三 IC



数据来源: WIND, 中信建投证券

图 14:因子三分组收益



数据来源: WIND, 中信建投证券

六、总结

在本篇研究中,我们在先前系列因子挖掘工作的基础上,精心构建了一个全面的基本面因子挖掘统一框架,该框架不仅整合了多种因子生成技术,并且能够自动优化基本面因子的频率和量纲。在此框架中融入了一系列常用算子,包括元素算子、时序算子和截面算子等,此外,为了进一步提升计算效率,我们在框架的底层采用了 cython 与流式计算技术的结合,这显著提高了因子计算的速度和性能。在因子筛选阶段,我们特别引入了因子相关性惩罚机制。这一机制的运用有效促进了因子的多样性,确保了最终生成的因子集合在保持低相关性的同时,也能捕捉到市场的有效信息。最终,我们展示了一些相关性较低且表现出色的基本面因子。

风险分析

本报告中所有数据结果是基于历史统计结果的展示，未来有可能发生风格切换导致因子失效的风险。模型运行存在一定的随机性，初始化随机数种子会对结果产生影响，单次运行结果可能会有一定偏差。历史数据的区间选择会对结果产生一定的影响。模型参数的不同会影响最终结果。模型对计算资源要求较高，运算量不足会导致结果存在一定的欠拟合风险。本文所有模型结果均来自历史数据，模型存在统计误差，不保证模型未来的有效性，对投资不构成任何建议。

分析师介绍

姚紫薇

金融工程及基金研究首席分析师。上海财经大学管理学硕士，厦门大学统计学学士，在基金研究、资产配置、产品设计、财富管理等领域均有长期深入研究。曾担任招商证券基金评价业务负责人，多次获得“新财富”金融工程方向前三（团队核心成员）

王 超：

南京大学粒子物理博士，曾担任基金公司研究员，券商研究员，有丰富的研究和投资经验，2021 年加入中信建投，主要负责量化多因子选股。

评级说明

投资评级标准		评级	说明
报告中投资建议涉及的评级标准为报告发布日后6个月内的相对市场表现，也即报告发布日后的6个月内公司股价（或行业指数）相对同期相关证券市场代表性指数的涨跌幅作为基准。A股市场以沪深300指数作为基准；新三板市场以三板成指为基准；香港市场以恒生指数作为基准；美国市场以标普500指数为基准。	股票评级	买入	相对涨幅 15%以上
		增持	相对涨幅 5%—15%
		中性	相对涨幅-5%—5%之间
		减持	相对跌幅 5%—15%
		卖出	相对跌幅 15%以上
	行业评级	强于大市	相对涨幅 10%以上
		中性	相对涨幅-10-10%之间
		弱于大市	相对跌幅 10%以上

分析师声明

本报告署名分析师在此声明：（i）以勤勉的职业态度、专业审慎的研究方法，使用合法合规的信息，独立、客观地出具本报告，结论不受任何第三方的授意或影响。（ii）本人不曾因，不因，也将不会因本报告中的具体推荐意见或观点而直接或间接收到任何形式的补偿。

法律主体说明

本报告由中信建投证券股份有限公司及/或其附属机构（以下合称“中信建投”）制作，由中信建投证券股份有限公司在中华人民共和国（仅为本报告目的，不包括香港、澳门、台湾）提供。中信建投证券股份有限公司具有中国证监会许可的投资咨询业务资格，本报告署名分析师所持中国证券业协会授予的证券投资咨询执业资格证书编号已披露在报告首页。

在遵守适用的法律法规情况下，本报告亦可能由中信建投（国际）证券有限公司在香港提供。本报告作者所持香港证监会牌照的中央编号已披露在报告首页。

一般性声明

本报告由中信建投制作。发送本报告不构成任何合同或承诺的基础，不因接收者收到本报告而视其为中信建投客户。

本报告的信息均来源于中信建投认为可靠的公开资料，但中信建投对这些信息的准确性及完整性不作任何保证。本报告所载观点、评估和预测仅反映本报告出具日该分析师的判断，该等观点、评估和预测可能在不发出通知的情况下有所变更，亦有可能因使用不同假设和标准或者采用不同分析方法而与中信建投其他部门、人员口头或书面表达的意见不同或相反。本报告所引证券或其他金融工具的过往业绩不代表其未来表现。报告中所含任何具有预测性质的内容皆基于相应的假设条件，而任何假设条件都可能随时发生变化并影响实际投资收益。中信建投不承诺、不保证本报告所含具有预测性质的内容必然得以实现。

本报告内容的全部或部分均不构成投资建议。本报告所包含的观点、建议并未考虑报告接收人在财务状况、投资目的、风险偏好等方面的具体情况，报告接收者应当独立评估本报告所含信息，基于自身投资目标、需求、市场机会、风险及其他因素自主做出决策并自行承担投资风险。中信建投建议所有投资者应就任何潜在投资向其税务、会计或法律顾问咨询。不论报告接收者是否根据本报告做出投资决策，中信建投都不对该等投资决策提供任何形式的担保，亦不以任何形式分享投资收益或者分担投资损失。中信建投不对使用本报告所产生的任何直接或间接损失承担责任。

在法律法规及监管规定允许的范围内，中信建投可能持有并交易本报告中所提公司的股份或其他财产权益，也可能在过去12个月、目前或者将来为本报中所提公司提供或者争取为其提供投资银行、做市交易、财务顾问或其他金融服务。本报告内容真实、准确、完整地反映了署名分析师的观点，分析师的薪酬无论过去、现在或未来都不会直接或间接与其所撰写报告中的具体观点相联系，分析师亦不会因撰写本报告而获取不当利益。

本报告为中信建投所有。未经中信建投事先书面许可，任何机构和/或个人不得以任何形式转发、翻版、复制、发布或引用本报告全部或部分内容，亦不得从未经中信建投书面授权的任何机构、个人或其运营的媒体平台接收、翻版、复制或引用本报告全部或部分内容。版权所有，违者必究。

中信建投证券研究发展部

北京
朝阳区景辉街16号院1号楼18层
电话：（8610）56135088
联系人：李祉瑶
邮箱：lizhiyao@csc.com.cn

上海
上海浦东新区浦东南路528号南塔2103室
电话：（8621）6882-1600
联系人：翁起帆
邮箱：wengqifan@csc.com.cn

深圳
福田区福中三路与鹏程一路交汇处广电金融中心35楼
电话：（86755）8252-1369
联系人：曹莹
邮箱：caoying@csc.com.cn

中信建投（国际）

香港
中环交易广场2期18楼
电话：（852）3465-5600
联系人：刘泓麟
邮箱：charleneliu@csci.hk